我的工作量：逐项看图讲清楚

从老师提出分层建议开始回顾；按解释顺序整理，工作之间有交叉进行。

上次老师让我分层。我完成分层后，继续换图片核验、补做比较，并把低分细化成具体的薄弱情况。

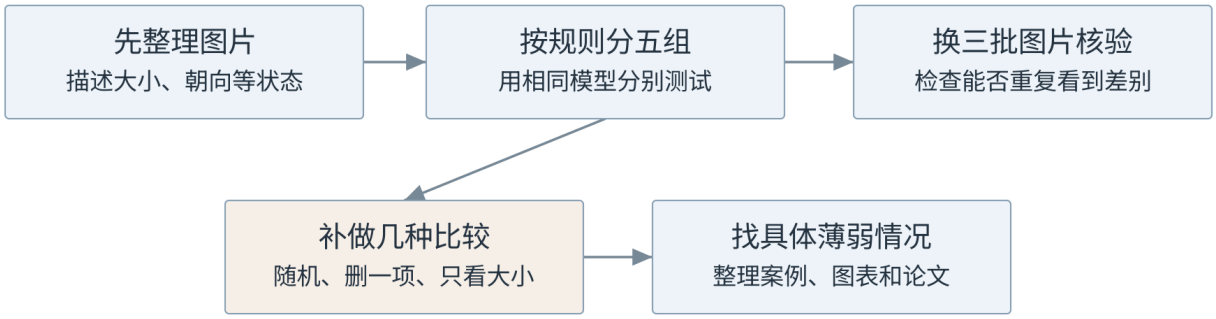


图 1 整体工作路线：不是只做一次分组，而是沿着结果继续检查。

已完成工作	具体工作量或产出
整理目标、描述状态、分成五组	狗、猫、马、羊、人、车六类；按五项条件分组。
沿用模型，换三批图片核验	8 种模型架构×3 份训练结果；后续核验 5400 个目标。
随机分组、去掉一项规则再试	每批随机分组 10000 次；依次去掉五项规则。
固定数量，改变困难图片比例	每次 120 个目标；21 种比例，每种抽样 1000 次。
只看大小对照、核验具体条件	比较简单方案；换来源、在大小相近组内检查条件。
案例、论文、计算材料整理	加入实际模型输入；核对结果，更新论文与图表。

下面每项工作都单独解释：为什么继续做、怎样操作、怎样看图、现在能得出什么结论。

阅读顺序：分层结果与各模型降幅（第 3—7 页）→换来源核验（第 8—10 页）→随机与去项检查（第 11—12 页）→固定数量实验（第 13—15 页）→后续对照与汇报稿（第 16—20 页）。

1 我怎样把图片分成五组?

先回答：老师说的“分层”，我实际怎样落实?

我具体做了什么

看五项条件：大小（占画面多大）、可见部分（身体露出多少）、遮挡（被其他东西挡住）、画面切掉（超出图片边缘）、朝向（正面、背面等）。按事先规则打分，在每类内部排序、均分五组。真实类别来自数据集；状态由两套 AI 和程序提供。

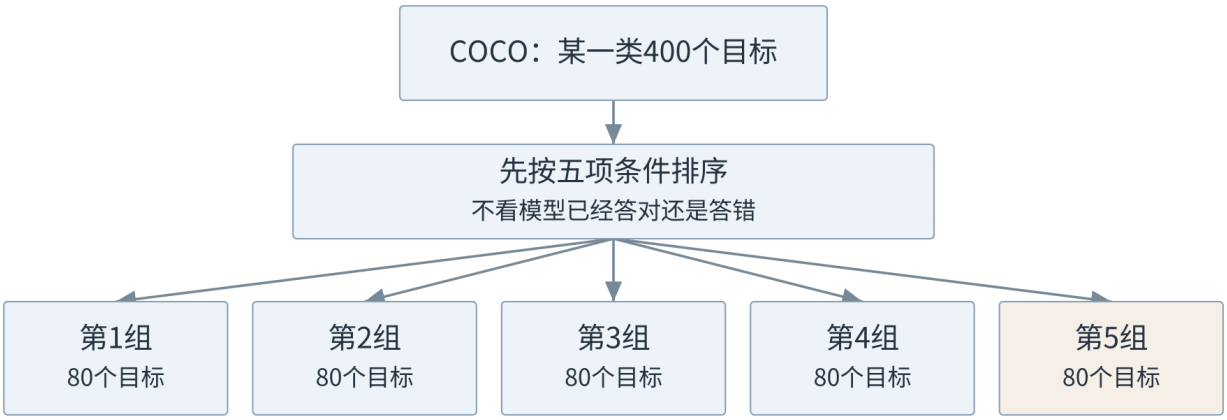


图 2 用 COCO 的一类 400 个目标解释实际分组数量；这不是虚构实验结果。

这张图怎么读

从上往下看：某一类 400 个目标，每组 80 个。六类分别这样分，因此每组有 480 个目标，而且类别比例相同。第一组预计较容易，第五组预计较困难。

结果说明什么

分组完成后，能比较条件不同的图片，而不是只报所有图片的平均分。分组时没有用模型的答错记录，因此不是先挑错误再说它难。

向老师可以这样讲

“我在每个类别内部划分五个等数量组，再分别测试，减少类别比例不同带来的影响。”

注意：这只是规则预计的相对难度，不是人工认定每张图片的难度；AI 状态描述也没有完整人工核对。

2 分层后，各模型的表现降低多少?

本节先看五组平均表现，接着直接比较 8 种模型的层间降幅。主口径：第 1 组 F1－第 5 组 F1，单位是百分点。

我具体做了什么

沿用 8 种模型架构、每种 3 份训练结果，共 24 份模型。分别计算五组的分类表现；后续比较没有重新训练这些模型。

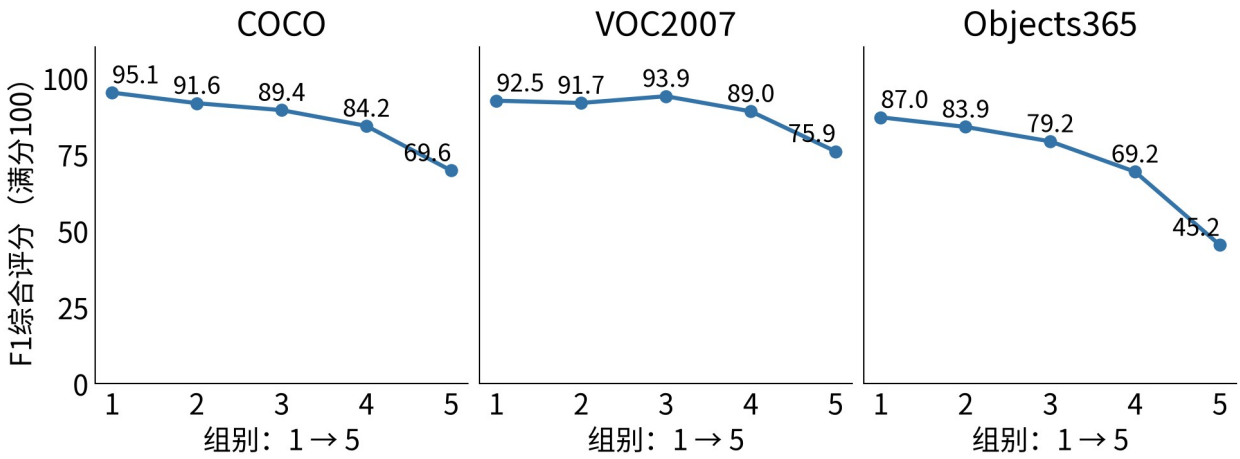


图 3 三批核验图片的五组结果；本地 AI 描述下，24 份已训练模型的平均 F1。

这张图怎么读

横轴 1 到 5 表示从规则预计较容易到较困难。纵轴是 F1 综合评分，换算成满分 100，越高越好。看整条线的变化，不只看两个端点。

结果说明什么

第五组都比第一组低。但中间几组不一定严格一步一步下降，例如 VOC2007 的第二组到第三组有局部回升。所以可以说两端有明显差别，不能说每一层都必然更难。

向老师可以这样讲

“五组分别测完后，最容易组和最困难组有明显分差；中间层的表现有波动，我也把它保留下来。”

F1 是综合评分，不是“100 张图片里认对多少张”的正确率。两套 AI 负责写状态描述；24 份模型负责分类，这是两种不同任务。

2.1 各模型降低多少：本地分组

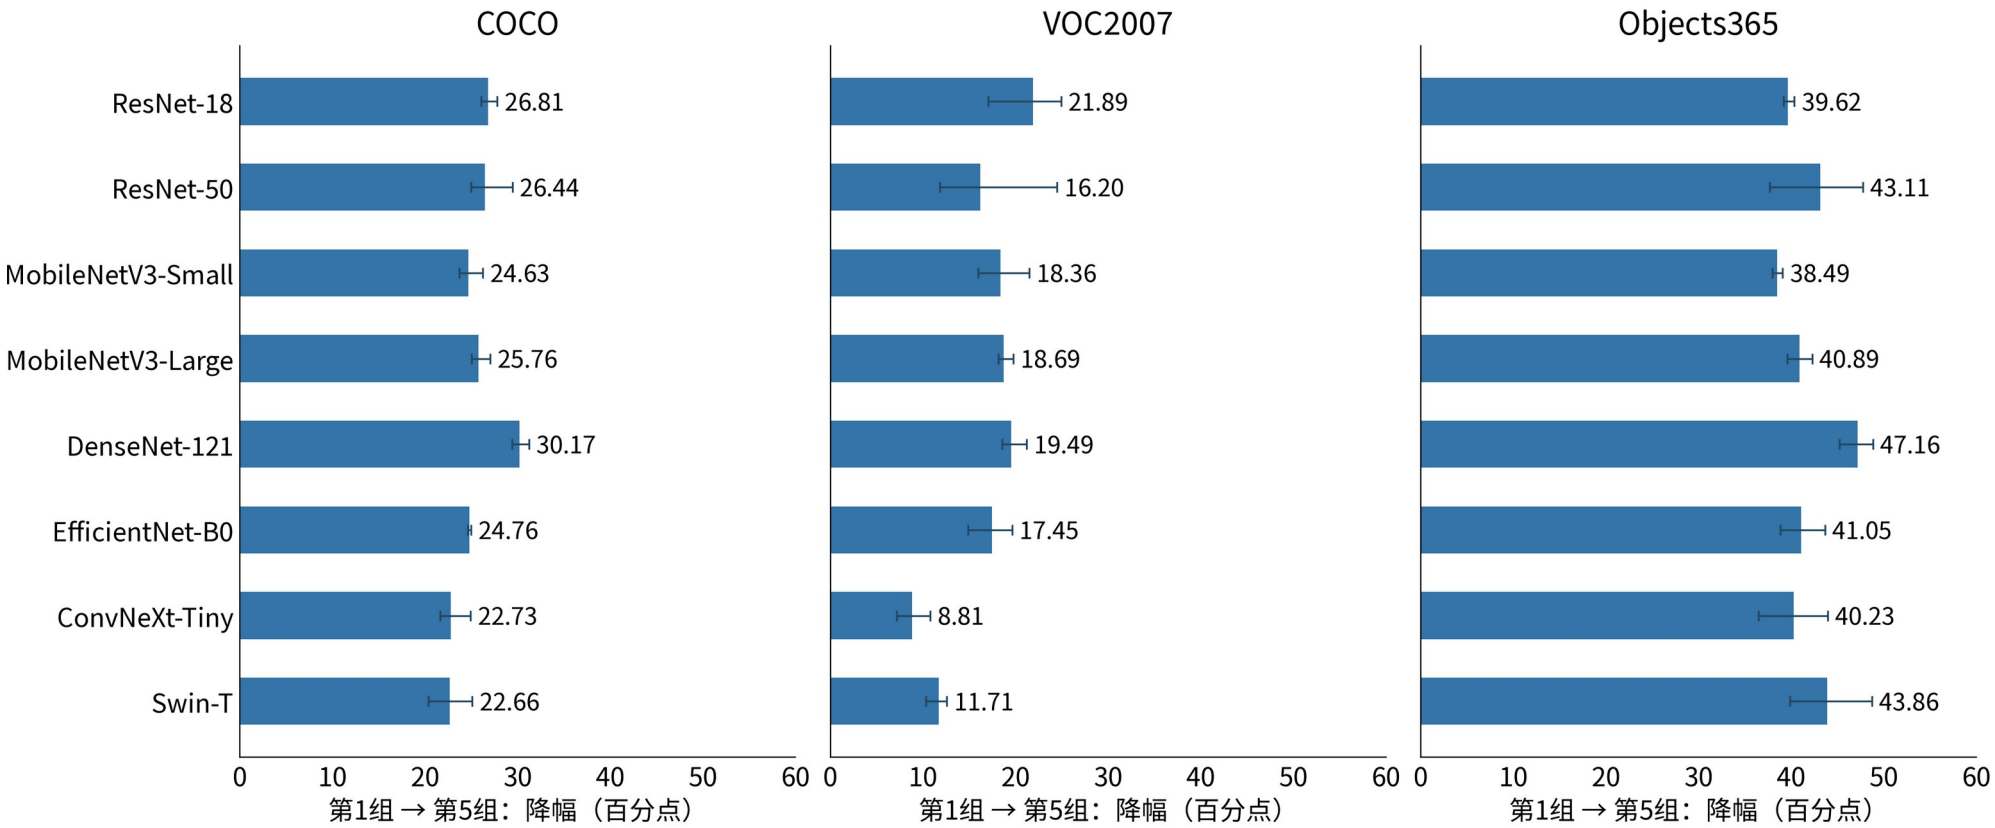


图 4 降幅＝第 1 组 F1－第 5 组 F1。每条横线对应一种模型；横条是 3 份训练结果的配对降幅均值，黑色短线是这 3 份配对降幅的最小—最大范围。

2.2 各模型降低多少：在线分组

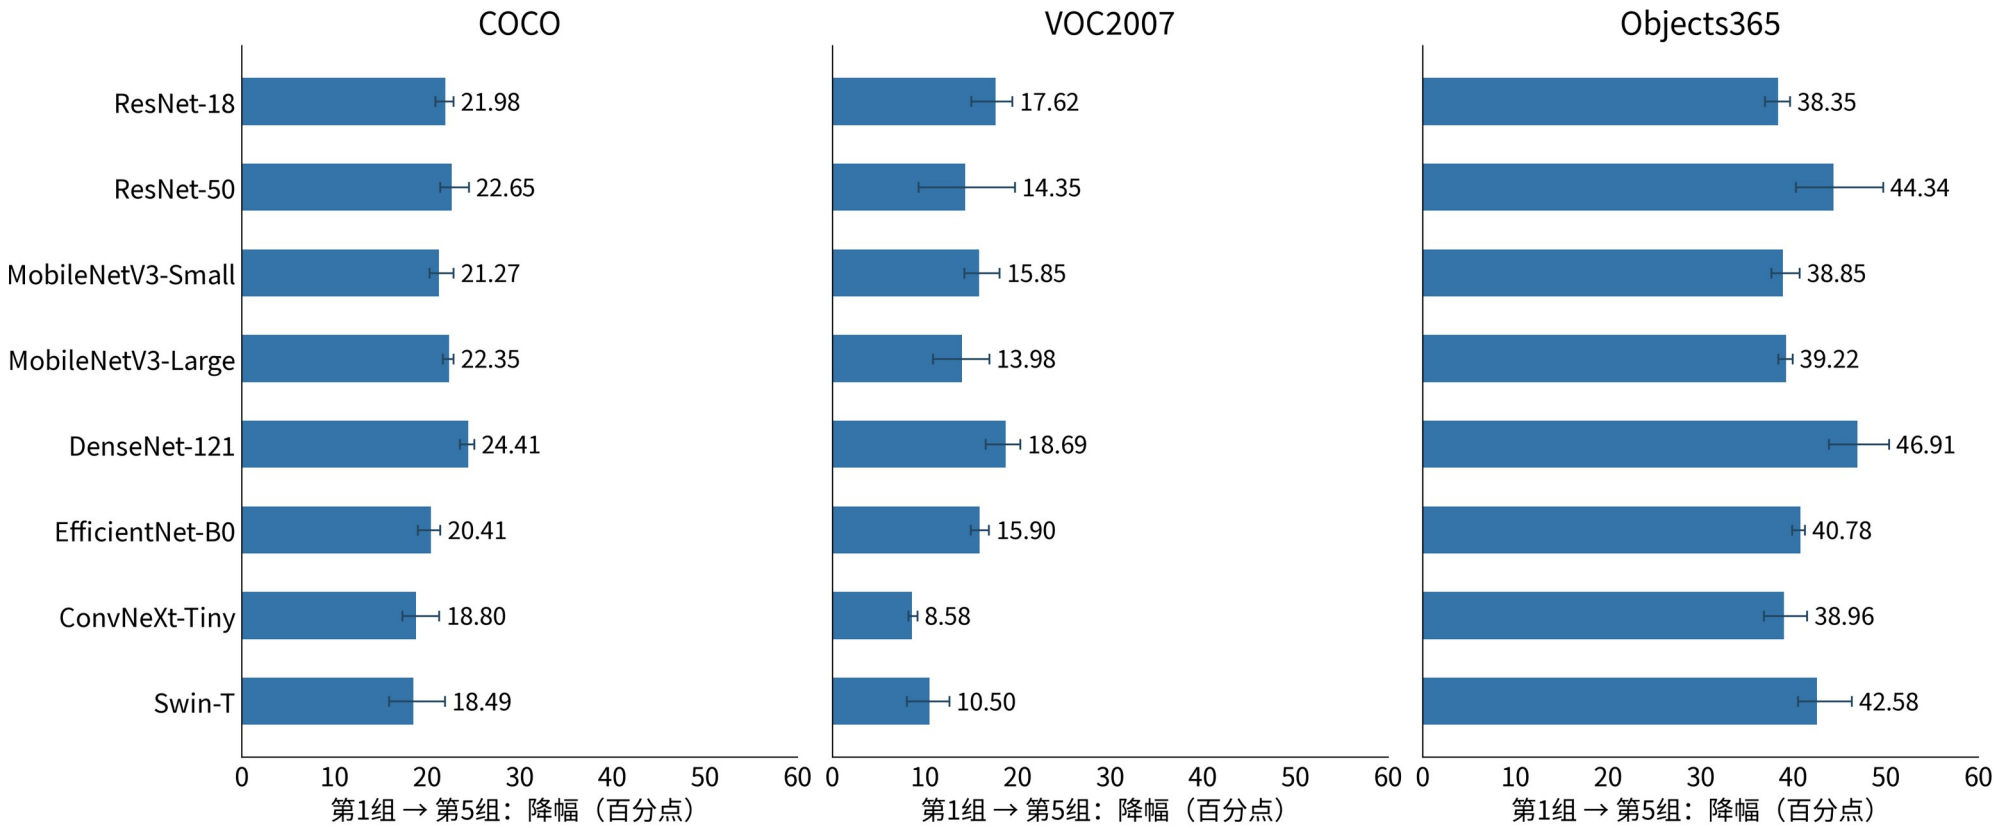


图 5 降幅＝第 1 组 F1－第 5 组 F1。每条横线对应一种模型；横条是 3 份训练结果的配对降幅均值，黑色短线是这 3 份配对降幅的最小—最大范围。

2.3 五组中的降幅变化：本地分组

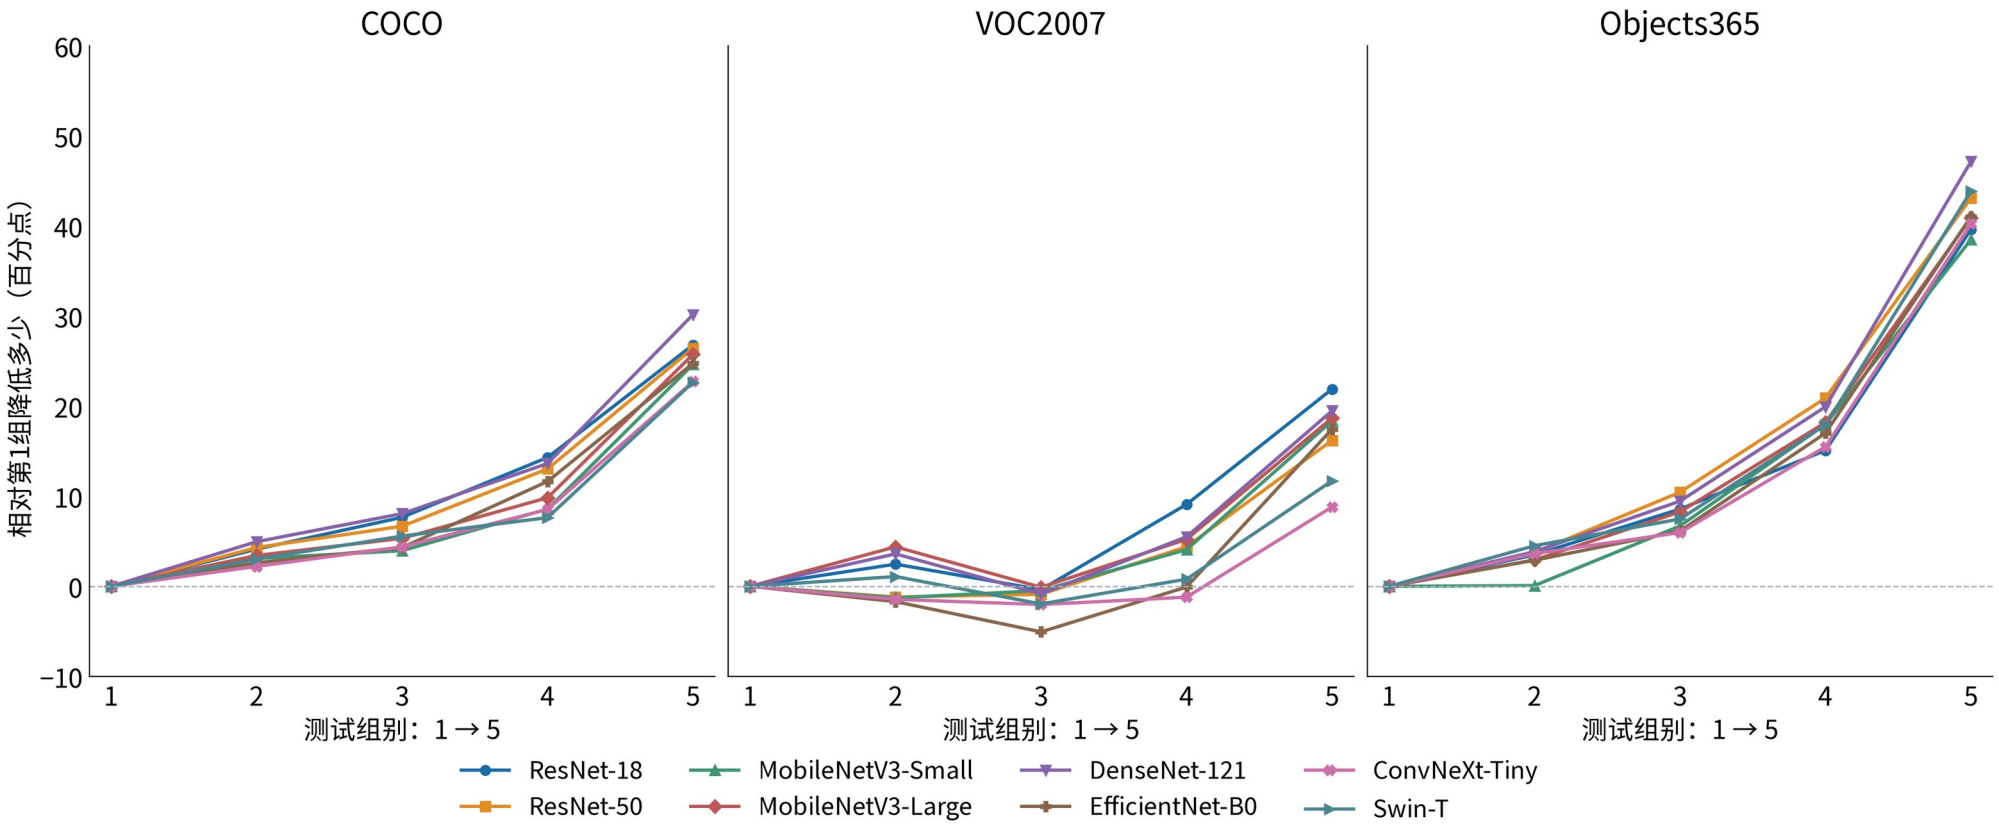


图 6 每条线是一种模型。以该模型第 1 组为零点，显示“第 1 组 F1－当前组 F1”的 3 份训练结果平均值。往上表示下降更多；负值表示该组比第 1 组高，中间组不一定逐步变差。

2.4 五组中的降幅变化：在线分组

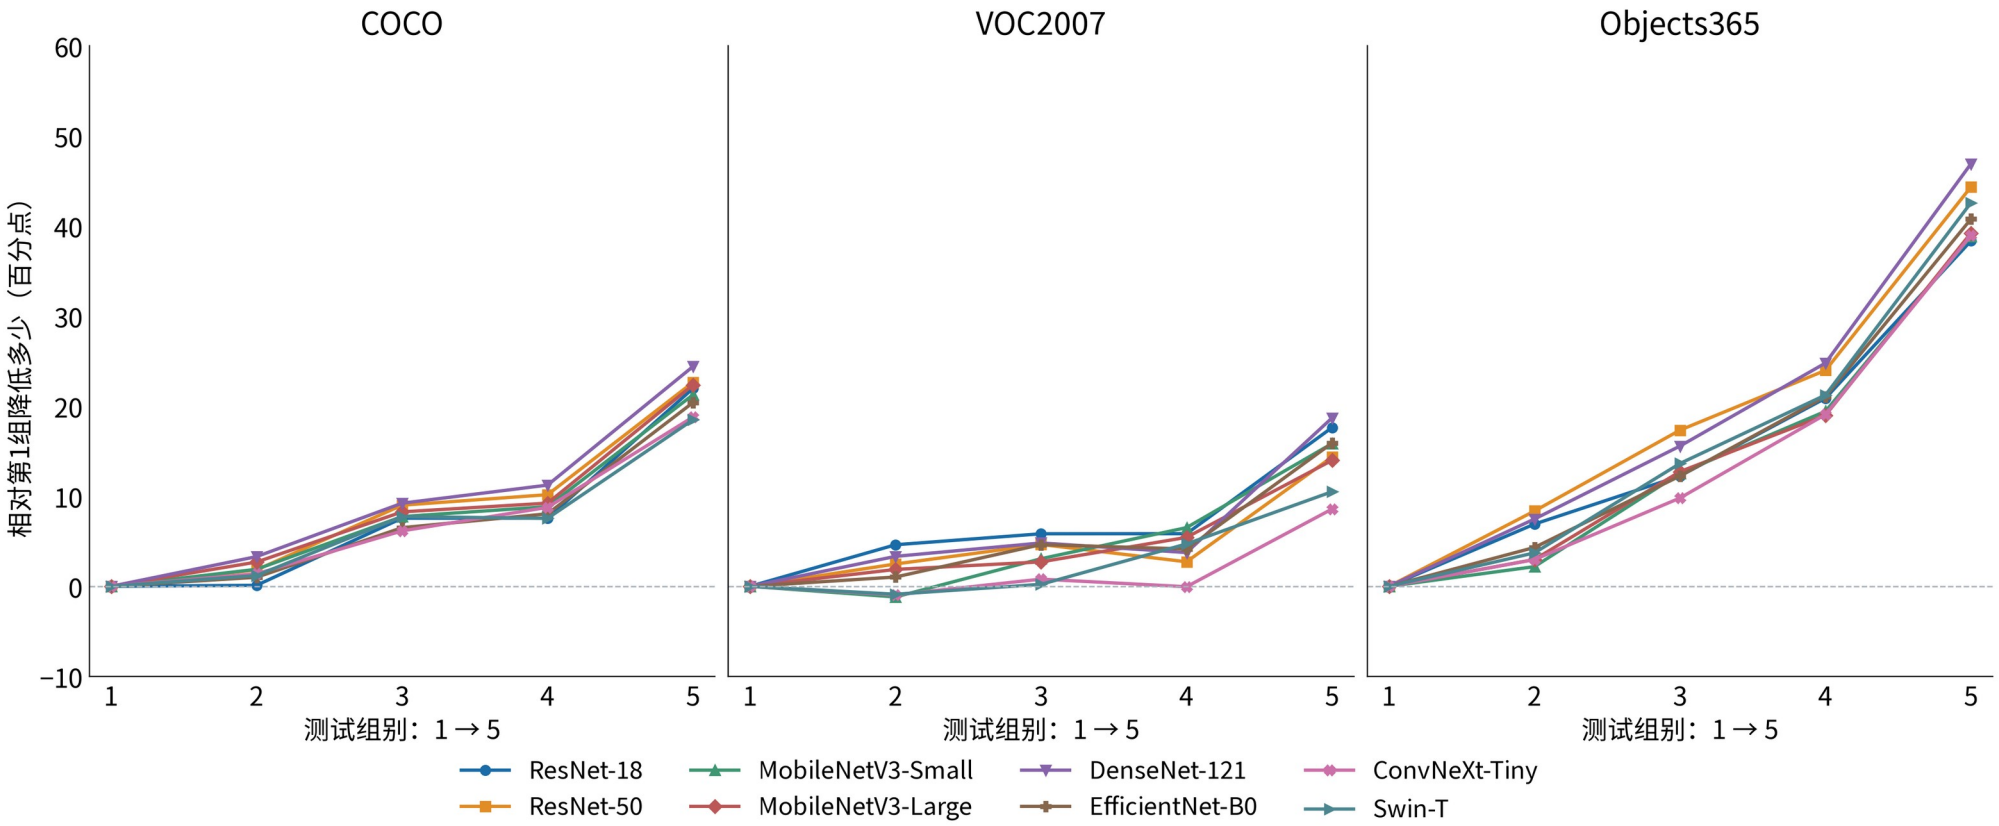


图 7 每条线是一种模型。以该模型第 1 组为零点，显示“第 1 组 F1－当前组 F1”的 3 份训练结果平均值。往上表示下降更多；负值表示该组比第 1 组高，中间组不一定逐步变差。

3 我为什么又换了三批图片？

换图片、换来源检查差别能否重复；本节后两页展示各模型降幅总览与两套分组的对照。

我具体做了什么

保留原来的模型和分组规则，建立 COCO 新样本 2400 个，再加入 VOC2007 的 600 个和 Objects365 的 2400 个目标。三批都包含相同六类。

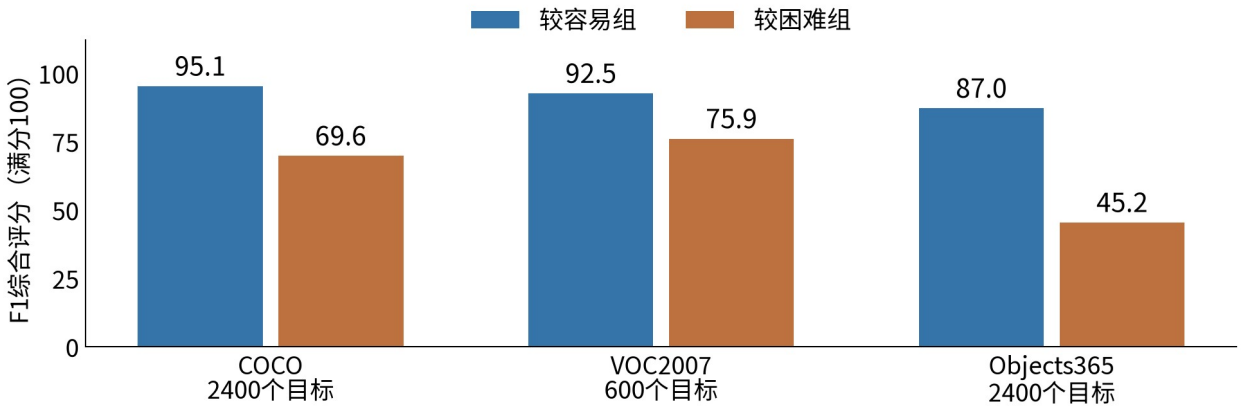


图 8 三批核验目标，共 5400 个；图中为本地 AI 描述结果，在线描述下也出现相同方向。

这张图怎么读

每个来源有两根柱：蓝色是第一组，橙色是第五组。三批的蓝柱都高于橙柱。COCO 是新样本核验；后两批还增加了不同来源。

结果说明什么

本地描述下，分差分别为 25.50、16.57、41.80 分；在线描述下为 21.30、14.44、41.25 分。差别在已测来源重复出现，范围约 14 到 42 分。

向老师可以这样讲

“我不是只测原来那一批；换了三批、共 5400 个目标后，较困难组平均分仍更低。”

COCO、VOC2007、Objects365 是三个公开图片数据集，相当于三套来源的考题。5400 是目标样本数，不一定是 5400 张不同原图。

3.1 各模型在三个来源的降幅总览

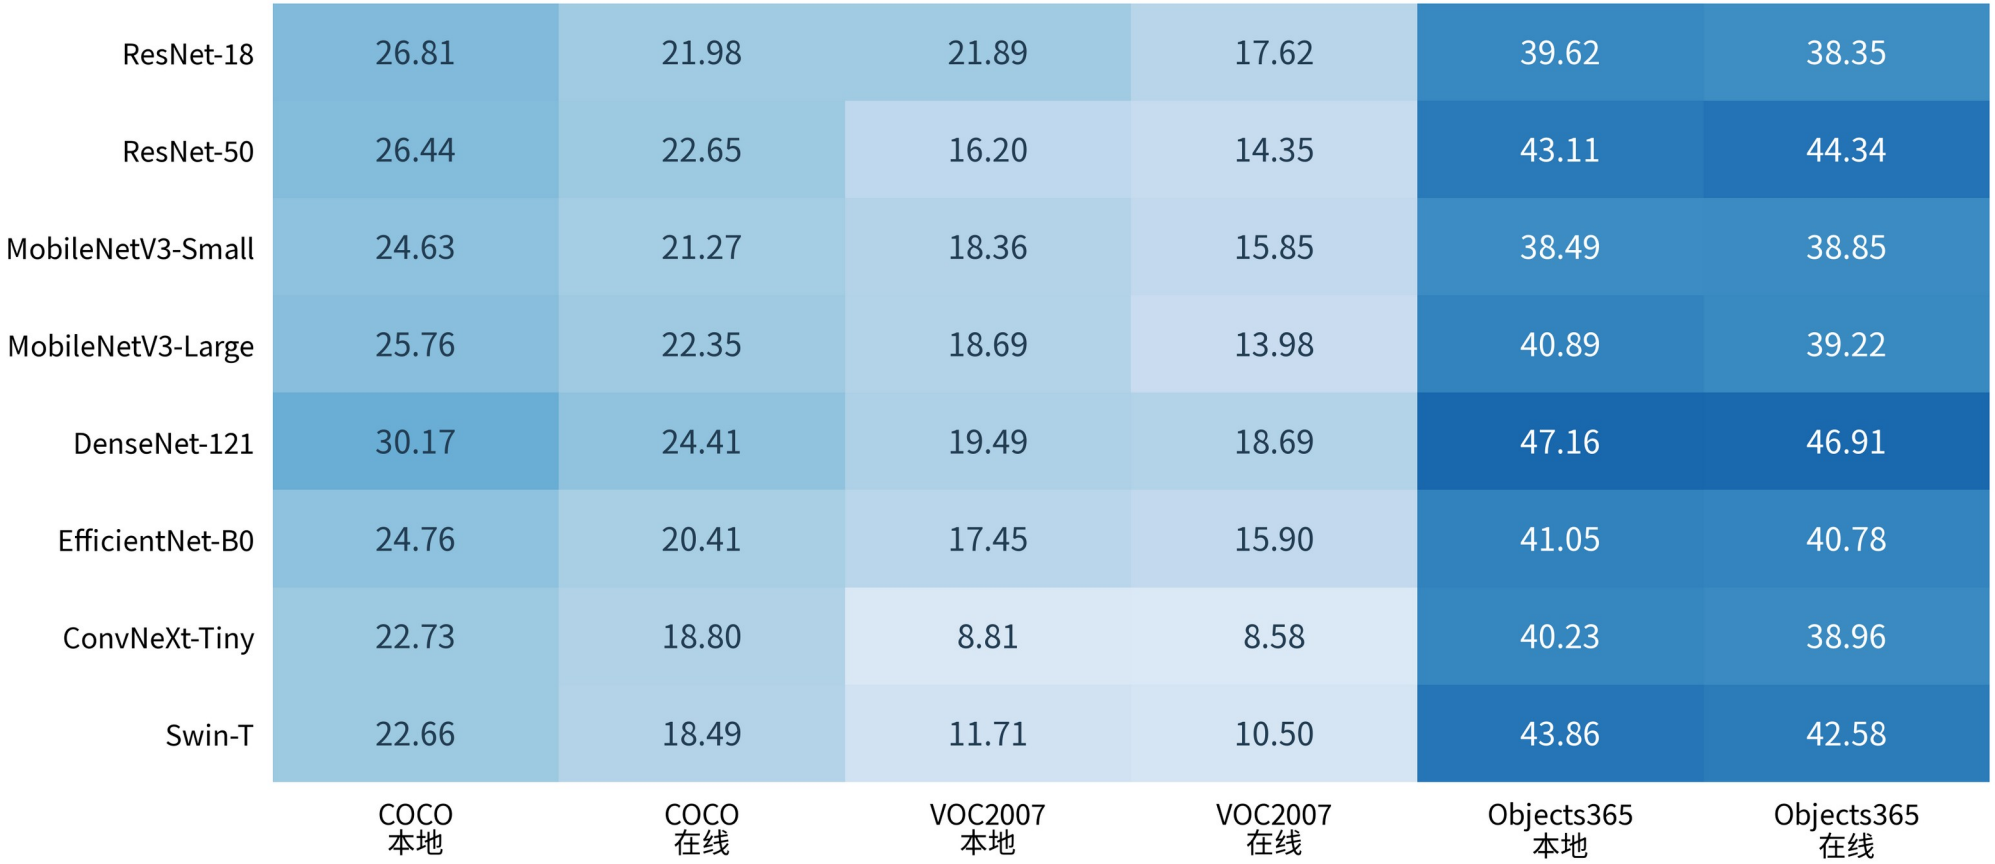


图 9 每行是一种模型；每个来源分别列本地和在线分组。数字均为“第 1 组 F1－第 5 组 F1”（百分点），颜色越深表示降幅越大。这里共 48 个模型平均降幅，全部大于零。

3.2 本地与在线分组的降幅对照

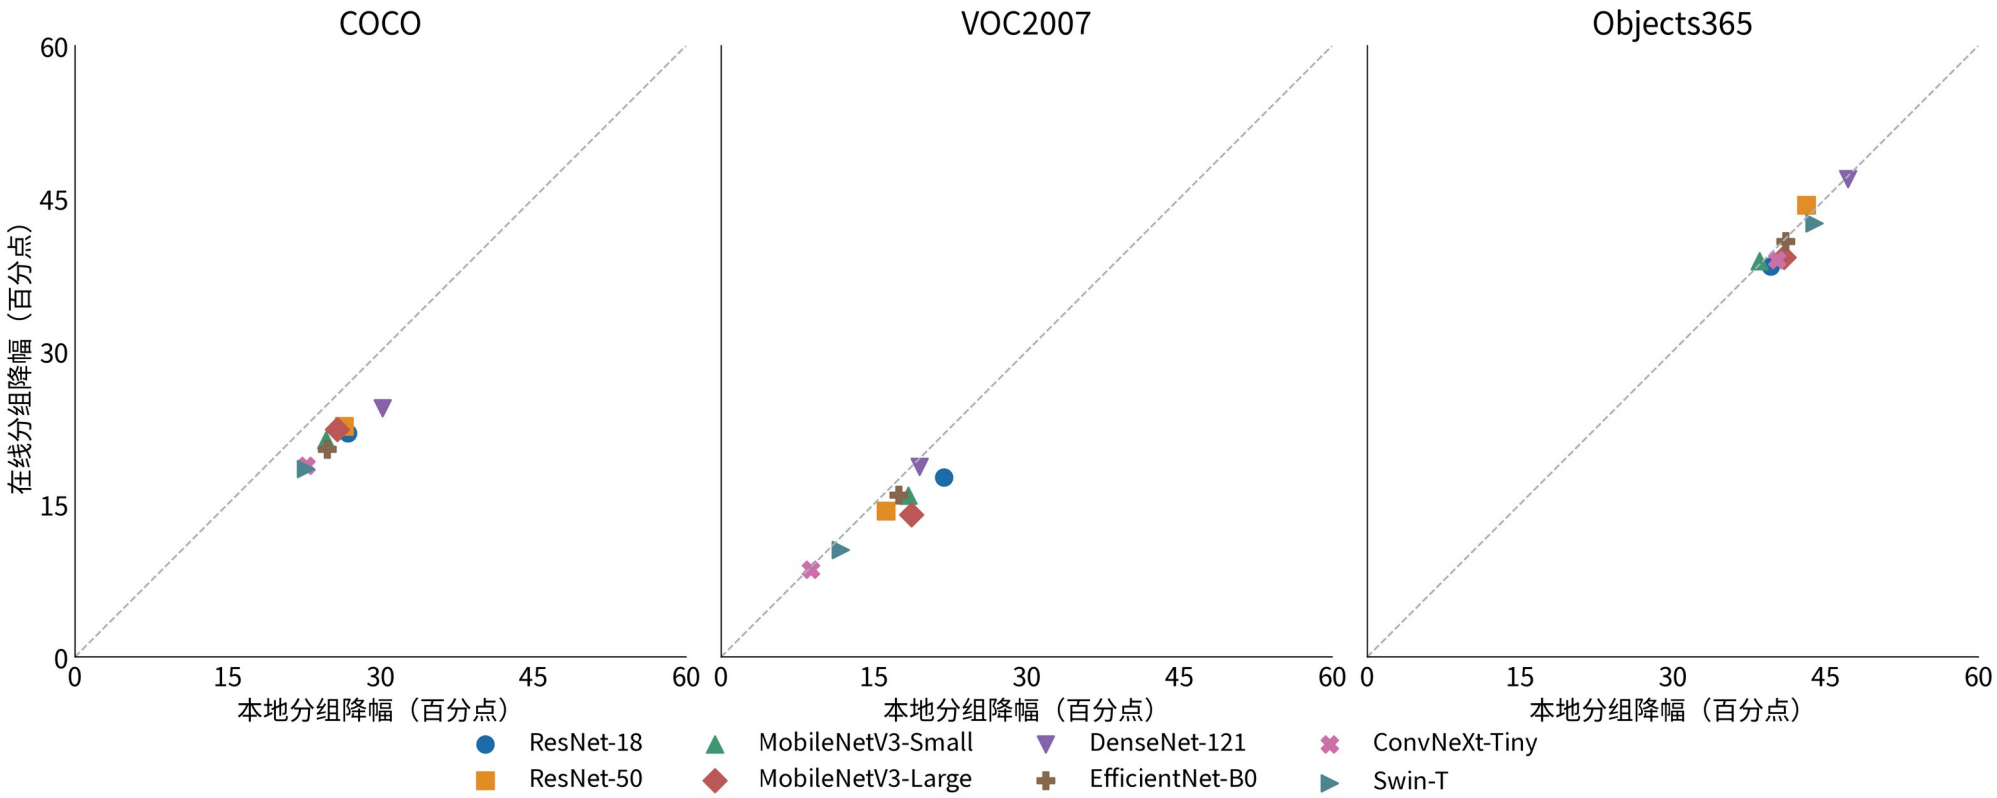


图 10 每个点是一种模型的 3 份训练结果平均降幅。越靠近虚线，两套分组测得的降幅越接近；在线降幅更大时点位于线上方。两套 AI 负责状态描述，不是被比较的 8 种分类模型；接近不等于标签一定正确。

4 随便分五组，也会有这么大差别吗？

这是检查偶然性：规则真的提供了信息，还是随便分都有差别？

我具体做了什么

在每个类别内随机打乱目标，再等分五组。组大小、类别比例和模型保持不变；每批做 10000 次，计算第一组与第五组的分差。

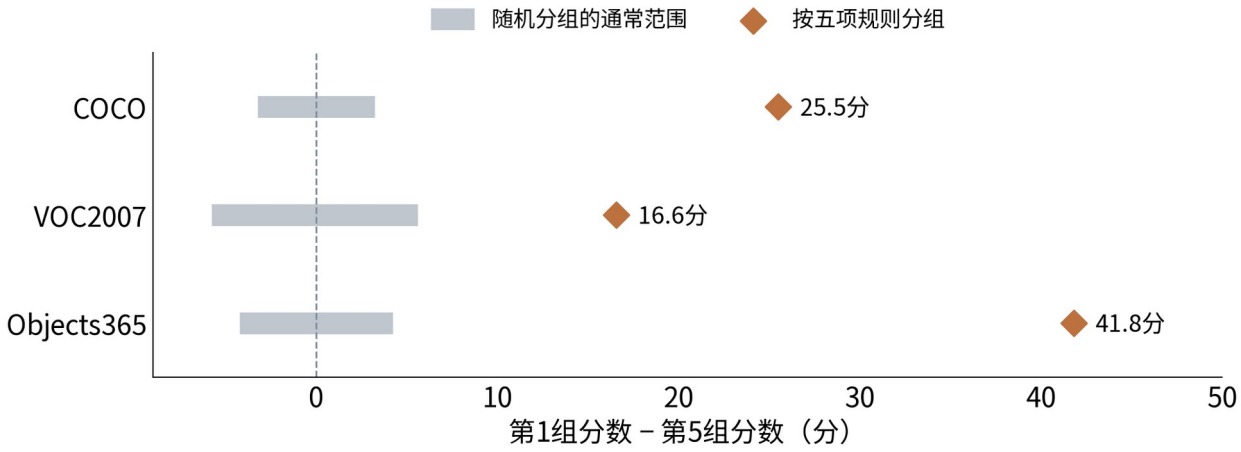


图 11 每批随机分组 10000 次；灰条显示其中中间 95%的范围，橙点是按五项规则得到的分差。

这张图怎么读

先找竖虚线：零表示两组分数一样。灰条在零附近，表示随机分组通常差别不大；橙点远在右边，表示按规则分组时第一组明显更高。

结果说明什么

实际规则分差明显大于随机波动。10000 次随机结果都没有达到实际分差的绝对值。这支持规则与模型表现有关，但还不能说规则已经最优。

向老师可以这样讲

“为了排除随便分组的偶然差别，我补做了随机分组对照。真实规则分组的差别明显更大。”

这些是对已有目标反复分组，不是重新采集 10000 批新图片；图上灰条也不是所有随机结果的最大范围。

5 我又把分组规则一项一项去掉

检查：差别是不是必须依赖某一项规则才能出现？

我具体做了什么

先保留完整五项作参照，然后分别去掉大小、可见部分、遮挡、被画面切掉、朝向。每次重新打分、重新划五组，再比较分差。

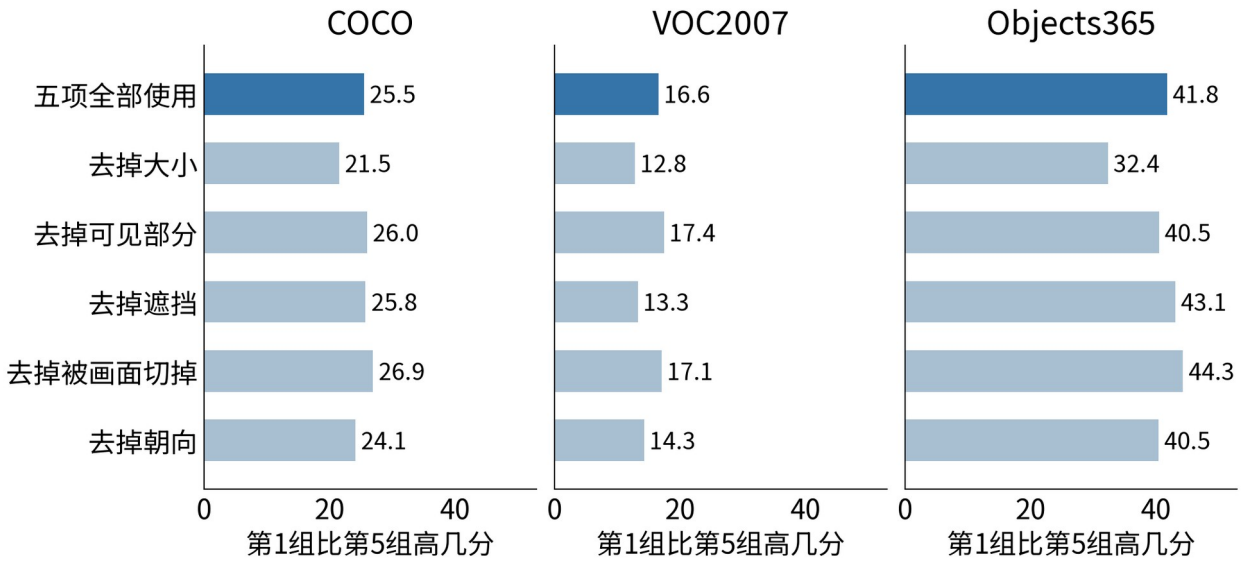


图 12 本地 AI 描述下的结果；横条越长表示第一组比第五组高得越多。在线结果也保留相同方向。

这张图怎么读

每个小图第一行是五项全用。往下每行只去掉一项。所有横条仍大于零，表示第一组平均分仍高于第五组。

结果说明什么

去掉任意一项后，主要方向还在。Objects365 去掉大小时，分差从 41.8 分缩到 32.4 分。但删一项也会改变分组成员，不能直接把变化当成该项的单独贡献。

向老师可以这样讲

“我逐项去掉规则再测，检查结果是否依赖某一项。方向还在，但目前不能确定各项独立起多大作用。”

也试过把不同项的分值范围拉齐、等权相加。结果方向保留；正式统计比较还没有确认每项差异，因此不据此宣称某项最重要。

6 数量不变，换困难图片的比例会怎样?

固定数量后，先看平均变化，再看 8 种模型相对 0%困难组起点的降幅曲线。此处起点来自第 1—4 组混合。

我具体做了什么

固定每次测试总量和类别比例，只增加第五组目标的比例：从 0%到 100%，每隔 5%测一次。模型保持不变。

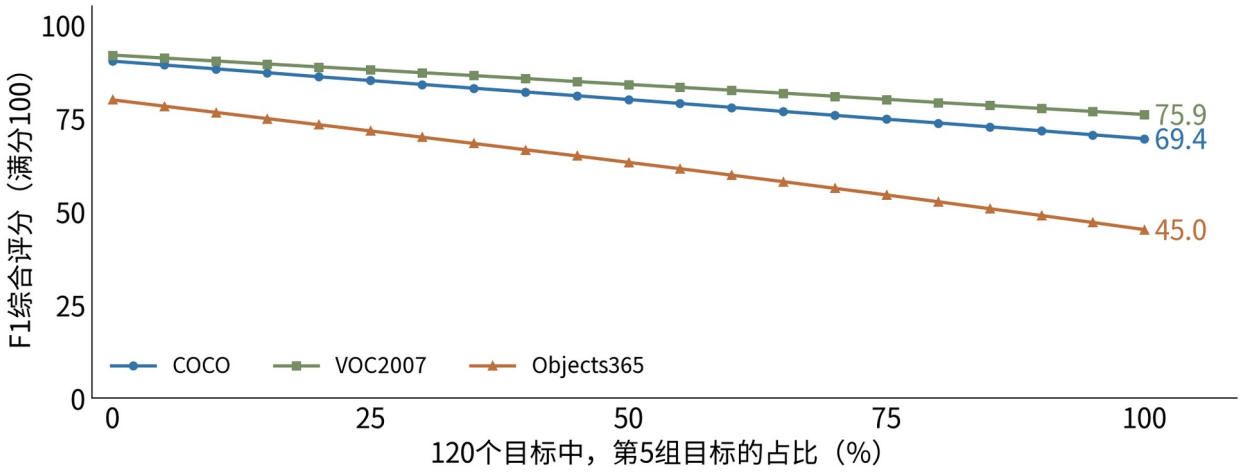


图 13 每次 120 个目标，六类各 20 个；21 个实际比例点，每点抽样 1000 次，展示本地描述下平均 F1。

这张图怎么读

横轴表示 120 个目标中有多少来自第五组，往右困难目标更多。纵轴是综合分。三条线对应三批来源，整体向下。

结果说明什么

本地描述下，从起点到终点，三批 F1 分别降低 20.78、15.92、34.77 分。说明同一个模型，换一套测试条件，总分就会变化；不是模型又训练后变差了。

向老师可以这样讲

“我把数量固定为 120 个，只改变困难目标占比。总分仍明显改变，所以评价模型还要交代考题的构成。”

0%从第一至第四组混合选，不是只选第一组。抽样 1000 次是反复选已有目标，也不等于新增 1000 批图片。

6.1 固定 120 个目标时的各模型降幅：本地分组

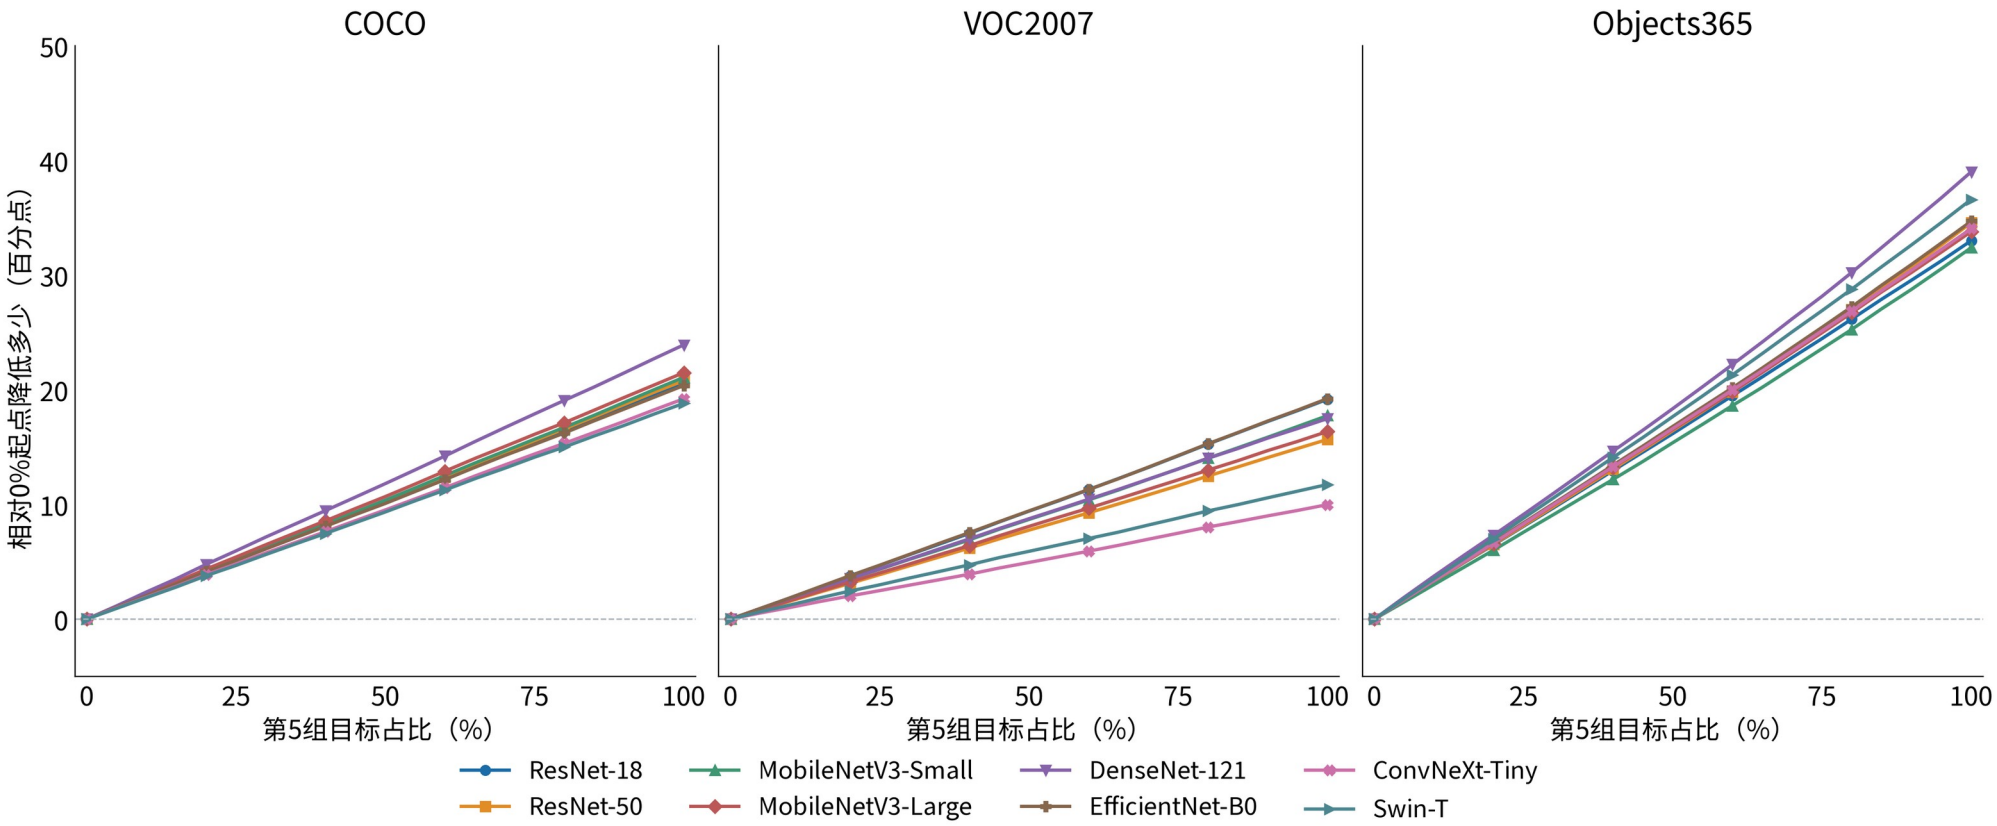


图 14 每次 120 个目标、六类各 20 个；21 种占比，每种抽样 1000 次。每条线是一种模型的平均 F1 降幅。此处基准是 0%第 5 组（从第 1—4 组混合取样），与前面单独第 1 组的基准不同；连线连接已有比例点，没有新增观测。

6.2 固定 120 个目标时的各模型降幅：在线分组

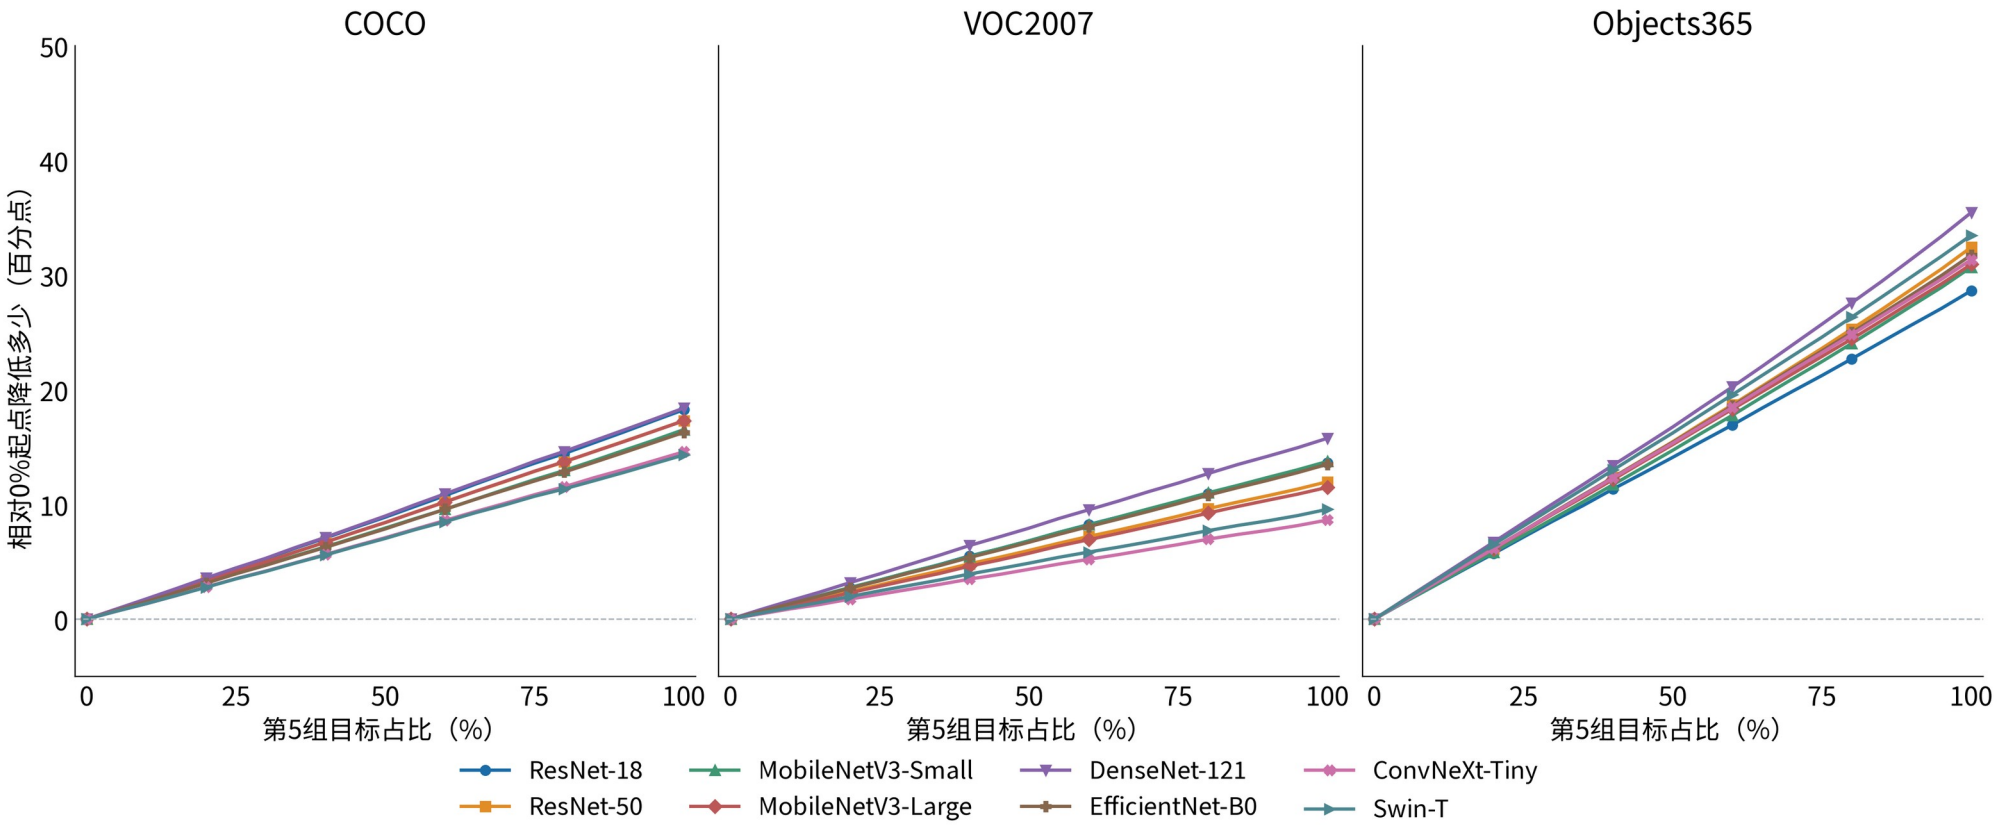


图 15 每次 120 个目标、六类各 20 个；21 种占比，每种抽样 1000 次。每条线是一种模型的平均 F1 降幅。此处基准是 0%第 5 组（从第 1—4 组混合取样），与前面单独第 1 组的基准不同；连线连接已有比例点，没有新增观测。

7 最新：只看目标大小，会不会也够用？

做一个更简单的方法作对照，才能知道复杂规则新增了什么。

我具体做了什么

不使用 AI 状态，只根据数据集标注框计算目标占原图的面积，按大小排序分五组。然后与原来的五项规则比较。

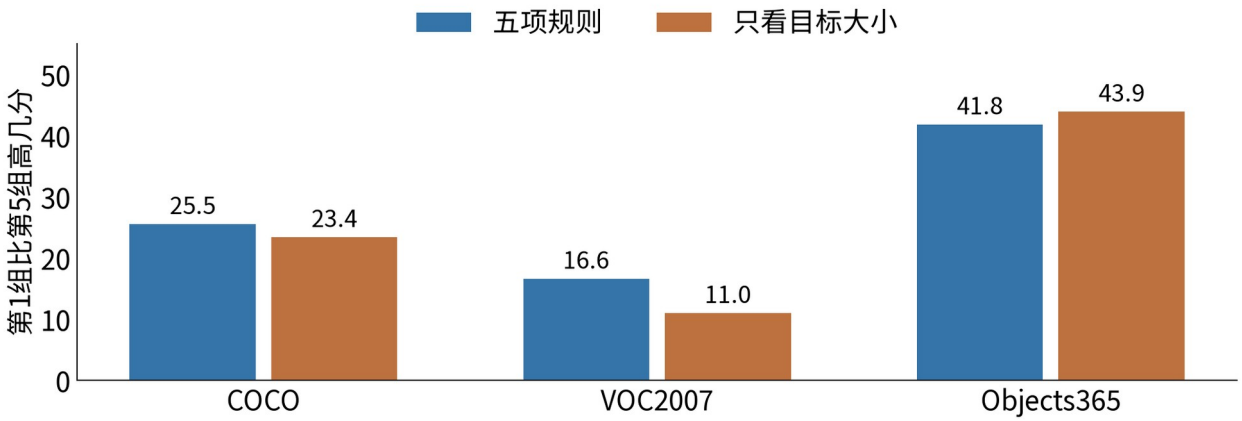


图 16 两种方案均按每类五等分；这里展示本地描述比较，完整核验还包括在线结果。

这张图怎么读

蓝柱是五项规则，橙柱是只看大小；纵轴是第一组与第五组的分差，不是模型总分。Objects365 的橙柱甚至比蓝柱更高。

结果说明什么

只看大小也能产生很大分差。五项规则没有在所有设置下更强；统计比较也没有确认其正向优势。因此“分差大”还不足以证明复杂规则一定更有价值。

向老师可以这样讲

“我新增了只按大小分组的简单对照，发现它也很强。后面重点就转到状态能否提供更具体的测试问题。”

完整比较中，COCO 在线描述的五项分差也比只看大小更小；不能只展示有利于五项规则的结果。

8 我怎样把“分数低”说得更具体?

老师通常还会问：那到底该重点测什么?

我具体做了什么

在最初的图片中整理表现较差的“模型＋具体条件”清单，先保留 175 项，再把同一清单放到新图片中核验。图中的 ResNet-50 是其中一种图片分类模型。

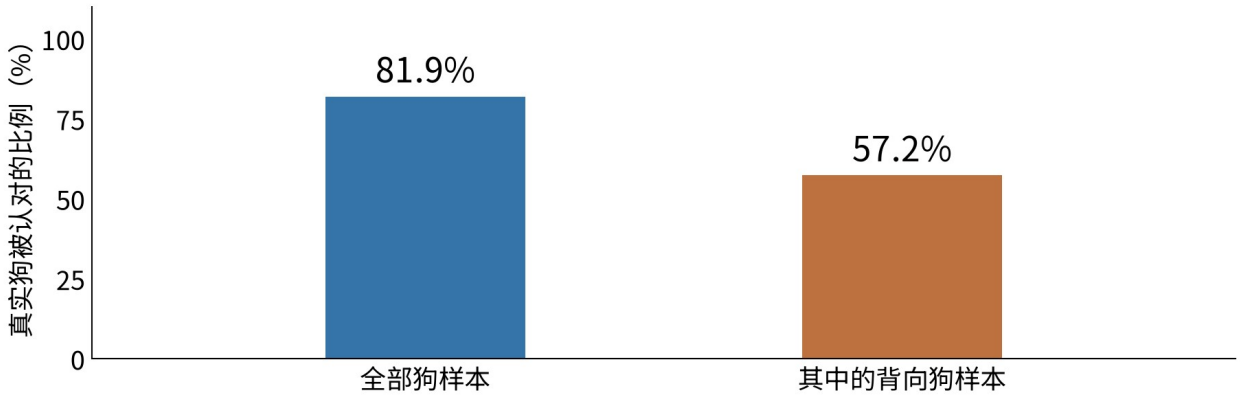


图 17 COCO 中 ResNet-50 的狗识别结果；背向狗子组有 46 个目标，数值是三份训练结果的平均。

这张图怎么读

左柱是全部真实狗样本中认成狗的比例，81.92%；右柱是其中背向狗的比例，57.25%。这里是 Recall，可以理解为真实狗被认对的比例。

结果说明什么

总体结果会掩盖具体情况。这个例子提示背向狗值得补测，但不代表每个模型都一样，也没有证明背向就是错误原因；有些原来薄弱的条件换图片后没有复现。

向老师可以这样讲

“我进一步把总分拆到具体条件。例如这个模型对全部狗识别率约 82%，背向狗只有约 57%，就能提出重点测试背向狗。”

175 项是模型与条件的组合，条件和目标会重叠，不等于 175 个独立缺陷。VOC 很多条件样本太少，不能把它们说成已稳定复现。

9 这些情况会不会只是因为目标太小?

既然大小本身很强，就继续检查朝向、遮挡等信息是否还有用。

我具体做了什么

从原来保留的清单中排除纯大小条件，剩 141 项。在每个类别内按大小分成五档，在相近大小档中比较某状态与非该状态。

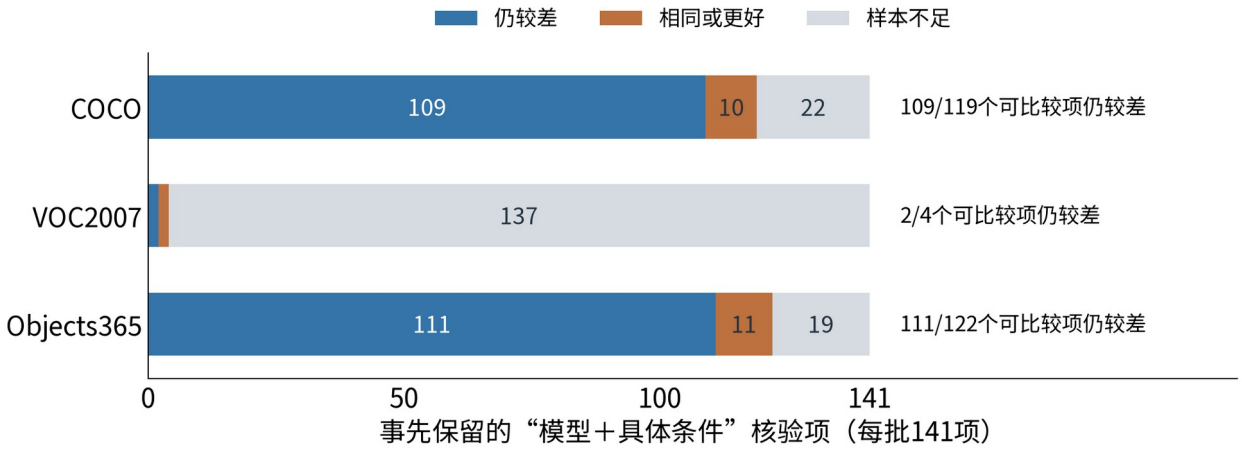


图 18 两套 AI 描述的核验项合并计数。蓝色仍较差；橙色相同或更好；灰色样本不足。

这张图怎么读

三行都从同一份 141 项清单出发。COCO 有 119 项能比较，其中 109 项仍较差；Objects365 有 122 项能比较，111 项仍较差。VOC 只有 4 项能比较，其余主要是灰色。

结果说明什么

在 COCO 和 Objects365 中，很多状态的较差表现，在粗略调整大小后仍存在。VOC 证据不足。“样本不足”表示暂时无法判断，不表示没有问题。

向老师可以这样讲

“为了排除大小的影响，我在大小相近的组内再比其他状态。两批中多数可比较项仍较差，另一批样本太少，需要保留不确定性。”

五个大小档并不等于把大小完全配成一样，其他条件也可能同时出现；这些是关联证据，计数不能当作独立错误数。

10 我还补了真实图片，解释模型看到了什么

只有统计图还不够：具体图片可以帮助理解测试流程。

我具体做了什么

从已有测试结果中整理真实案例，把原图里的目标框、送给模型的裁剪输入和预测并排放出来。案例没有重新生成，也没有人工改状态标签。

原图：橙框内是真实狗目标



模型实际看到的裁剪输入



真实类别：狗

同一架构三份训练结果

分别认成：人 / 车 / 人

AI状态描述：背向

这个例子三次都认错

先看模型的实际输入；原图中的清晰上下文，并不都进入分类器。

图 19 复用既有真实案例：原图、实际模型输入、真实类别和三份模型预测。状态由 AI 自动描述。

这张图怎么读

先看左图橙框，真实类别是狗。中间是模型实际看到的裁剪输入，已经很模糊。右边显示同一架构三份训练结果分别认成了人、车、人。

结果说明什么

原图的上下文和模型实际输入不同。小目标经放大、裁剪后，可能丢失信息，所以不能把错误全部归到朝向或模型结构上。这个案例解释现象，不估计所有图片的错误率。

向老师可以这样讲

“我补了真实输入案例，帮助说明模型究竟看到了什么。除了状态，目标裁剪和预处理也需要纳入结果解释。”

这一例是在符合既有条件的错误案例中按固定顺序选出；它不是人工核对，也不是随机抽样，不能代表总体失败比例。

11 最后整理了什么？怎样向老师汇报？

把前面的实验变成可查看、可解释、可重新计算的材料。

已经完成的材料工作

我更新了中英文论文，把新对照、具体条件、真实图片和局限写进去；同时整理图表、补充结果与计算材料。利用保存的预测核对计算，8 张新增结果表和 60 项历史比较与原结果一致。这是结果复算，不是从零重新训练。

约 3 分钟汇报稿

老师，上次您建议我对测试图片做分层。我先按照目标大小、可见部分、遮挡、画面切掉和朝向，把六类目标分别划成五个等数量组，用原来训练好的模型分别测试。

有了初步差别以后，我保留规则又换了三批图片核验，共 5400 个目标。三批里较困难组的平均分都低于较容易组，两套 AI 描述下，差值约 14 到 42 分；但中间组不是每一步都下降。

我又补了三种检查：每批随机分组 10000 次；分别去掉一项规则重新分组；每次固定 120 个目标，逐步增加困难目标比例。这些检查帮助说明差别不是随便分组就能出现，同一个模型的总分也需要结合测试图片构成来解释。

最新我补了只看目标大小的对照。它本身也很强，所以还不能说五项规则一定更好。我接着找更具体的测试问题，例如这个模型对全部狗的识别率约 82%，背向狗约 57%。再换图片、在大小相近的组内比较后，两批里很多可比较条件仍较差；另一批样本少，暂时不好判断。

最后我加入了真实输入案例，更新了论文和计算材料。现在的主要成果，是把总体成绩展开成具体测试条件，帮助决定接下来重点测什么。状态是 AI 自动描述，找到的还是相关薄弱情况，没有证明错误原因，也没有完成模型修复。

讲图时，用这四句就够了

① 我为什么做这一步？
② 图的横轴、纵轴或颜色是什么意思？
③ 最应该看哪两个位置，它们有什么差别？
④ 这个差别让我知道了什么，还有什么不能确定？

数值与核查来源：
random_stratification_ablation_20261006、controlled_risk_distribution_20261005、scale_only_confirmation_20261007、submission_closeout_20261007 及 docs/论文_最新.md。实验目录位于当前工作目录 artifacts 下；逐图数据与生成脚本在随附图表素材包中。