从老师的分层建议，到可解释的模型诊断

研究进度汇报 · 图文讲解版 · 2026 年 10 月 8 日

汇报起点：上次老师建议对测试数据进行分层。本轮先完成分层，再验证分层是否有效、能否复现、能指出哪些具体薄弱条件。

本次汇报的一条主线

把总体分数展开为风险层表现和具体条件报告；通过新样本、新来源和简单对照，明确这种测试组织的用途及边界。

步骤	我做了什么	回答什么问题
1	五维风险、类别内五等分	怎样落实分层建议?
2	新 COCO 样本、VOC、Objects365 确认	换图片、换来源还成立吗?
3	冻结薄弱状态，在新池确认	能指出下一步具体该测什么?
4	随机划层与风险字段消融	差异是随机的吗？依赖单字段吗?
5	固定 120 目标，改变 Q5 占比	测试构成如何影响测得能力?
6	仅面积对照、面积层内条件诊断	状态信息超出了目标大小吗?
7	论文、真实案例与复算材料	结果如何解释、复查和使用?

可以这样向老师讲

> 老师，上次您建议我做分层。我先把分层规则落实，再围绕结果做了几类验证：检查新样本与新来源是否复现，检查随机分组和风险字段的影响，进一步形成具体状态诊断，最后补了仅按目标大小分层的对照。

阅读方式：每一页对应一个汇报问题，并提供“怎么看图”“可以怎么讲”与后续追问。顺序服务于解释，部分实验实际执行时交叉进行。

01 我怎样落实老师的分层建议?

先按视觉条件组织样本，再评价冻结分类器

六分类：dog、cat、horse、sheep、person、car。person 是人体目标。八种架构各三个种子，共 24 份权重；训练和 checkpoint 选择完成后保持冻结。

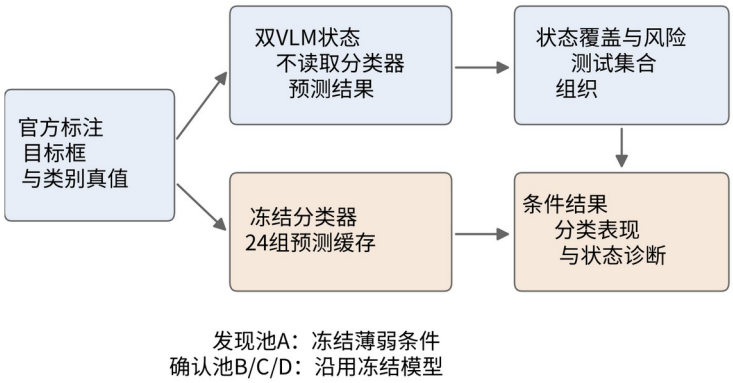


图 1 官方类别负责分类真值，VLM 负责状态描述；分类器预测用于结果评价。

风险维度	评分依据
目标尺度	官方框面积/原图面积：越小分数越高（0—3）
身体可见性	完整/大部分 0，部分 2，极少 3
遮挡	无 0、轻 1、中 2、重 3
截断	无 0、轻 0.5、中 1、重 2
朝向	常规 0、背向 1、俯视/异常 2

五项相加得到 0—13 分风险代理，每类内部排序并均分 Q1—Q5。每类 400 目标时，每层每类 80 个、六类共 480 个。Q5 是池内相对高风险，分层不读取分类错误或置信度。

可以这样向老师讲

> 我用五项视觉信息，在每个类别内部划分五个等数量风险层。先组织条件、再看模型表现，并保持高低层类别比例相同。这样可以减少“某层只是包含更多难类别”的解释。

接下来追问：在原样本上能区分表现，换一批图片是否仍然成立?

02 分层结果能在新样本、新来源上复现吗?

冻结规则后的三个确认池：5400 个目标

初始池中，本地标签 Q1/Q5 平均 F1 为 94.90%/82.67%，线上为 93.68%/84.35%。之后建立新 COCO 样本池，并加入 VOC2007、Objects365；沿用模型、评分和指标。

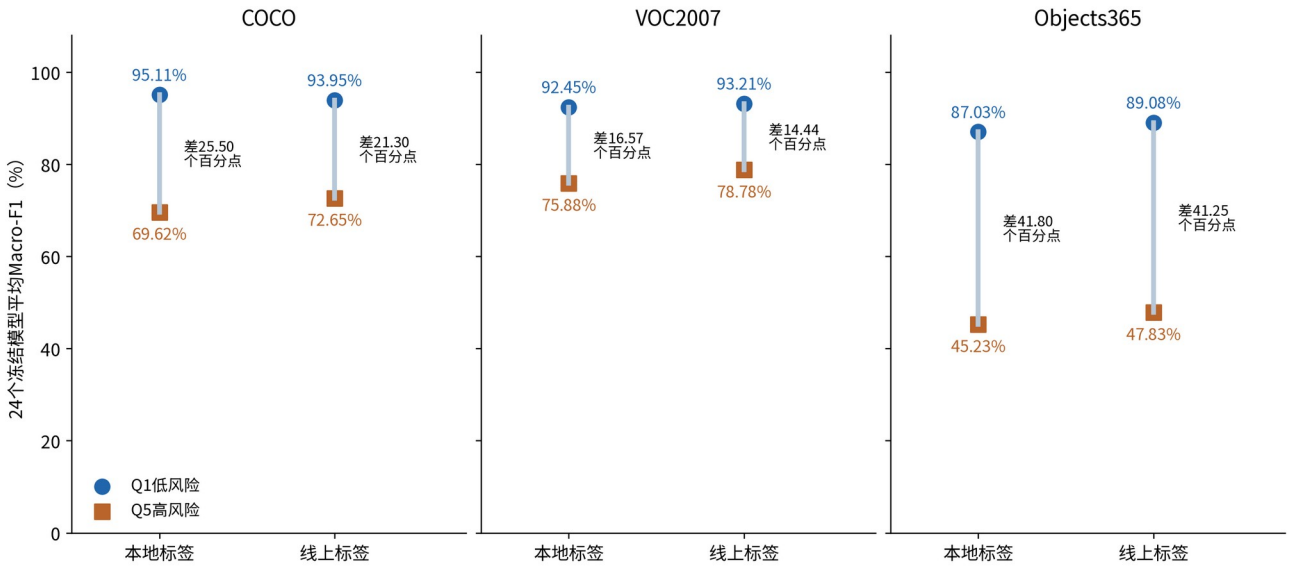


图 2 每条线连接同一确认设置的 Q1 与 Q5。点为 24 运行平均值；本图没有添加误差条。

确认池	目标数	本地 Q1−Q5	线上 Q1−Q5
COCO	2400	25.50 个百分点	21.30 个百分点
VOC2007	600	16.57 个百分点	14.44 个百分点
Objects365	2400	41.80 个百分点	41.25 个百分点

怎么看图

同一设置中，蓝色低风险点均高于橙色高风险点。落差在多个已测来源重复出现；中间层不要求严格递减。新 COCO 只属于新样本确认，VOC/Objects365 增加来源证据。

可以这样向老师讲

> 分层有初步差异以后，我固定规则继续确认。三个确认池中，高风险层平均 F1 都较低，落差约十四到四十二个百分点。现象能够在多个来源重复出现，但不意味着每个具体状态都能迁移。

03 分层之外，我定位了哪些具体薄弱条件？

把“模型平均表现怎样”展开为“下一步具体该测什么”

在发现池 A 中冻结 175 条状态—架构组合：状态至少 20 个目标、Recall 比类别总体低至少 10 个百分点；随后沿用同一清单到新池确认。

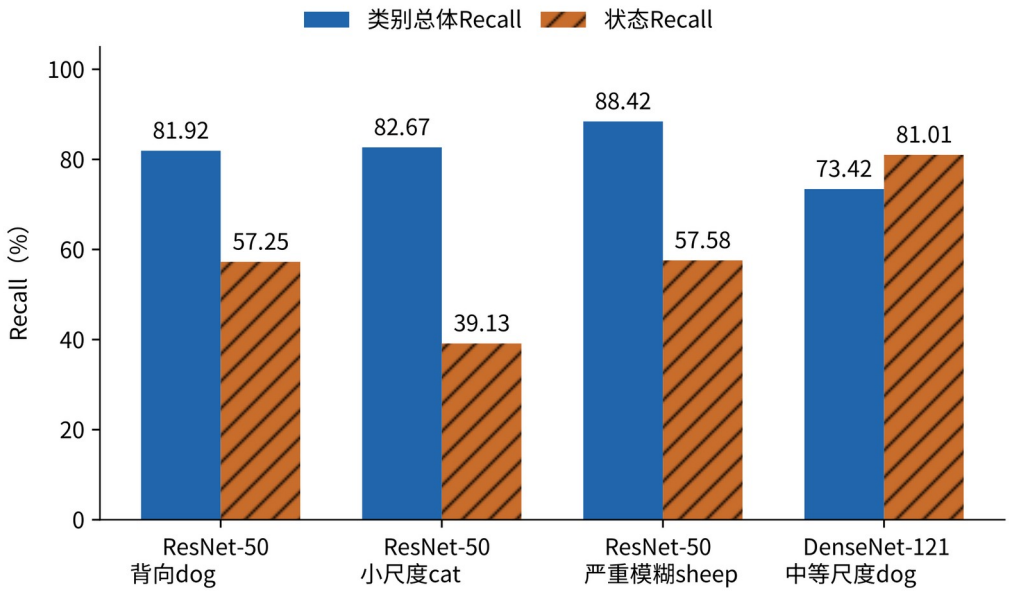


图 3 同一模型的类别总体 Recall 与具体状态 Recall；第四例保留未复现的正向差。

重点讲一个例子

COCO 中，ResNet-50 的 dog 总体 Recall 为 81.92%，背向 dog 的 46 个目标 Recall 为 57.25%，低 24.67 个百分点。Recall 表示真实 dog 被正确识别为 dog 的比例。

确认池	175 条清单中可评价组合	解释
COCO	153	支持充分时可检查既有薄弱条件
VOC2007	4	多数状态支持不足，不概括为稳定迁移
Objects365	160；其中 142 个为负方向	组合会重叠，不是 142 个独立缺陷

可以这样向老师讲

> 接着我把分层往条件诊断推进。例如 dog 总体 Recall 超过百分之八十，但背向 dog 只有百分之五十七左右。报告就可以提出明确的后续测试需求。我提前冻结条件，再到新池确认，减少只挑当前失败案例的问题。

04 任意随机分成五组，会得到同样差异吗?

随机划层对照：每池 10000 次，层大小和类别比例不变

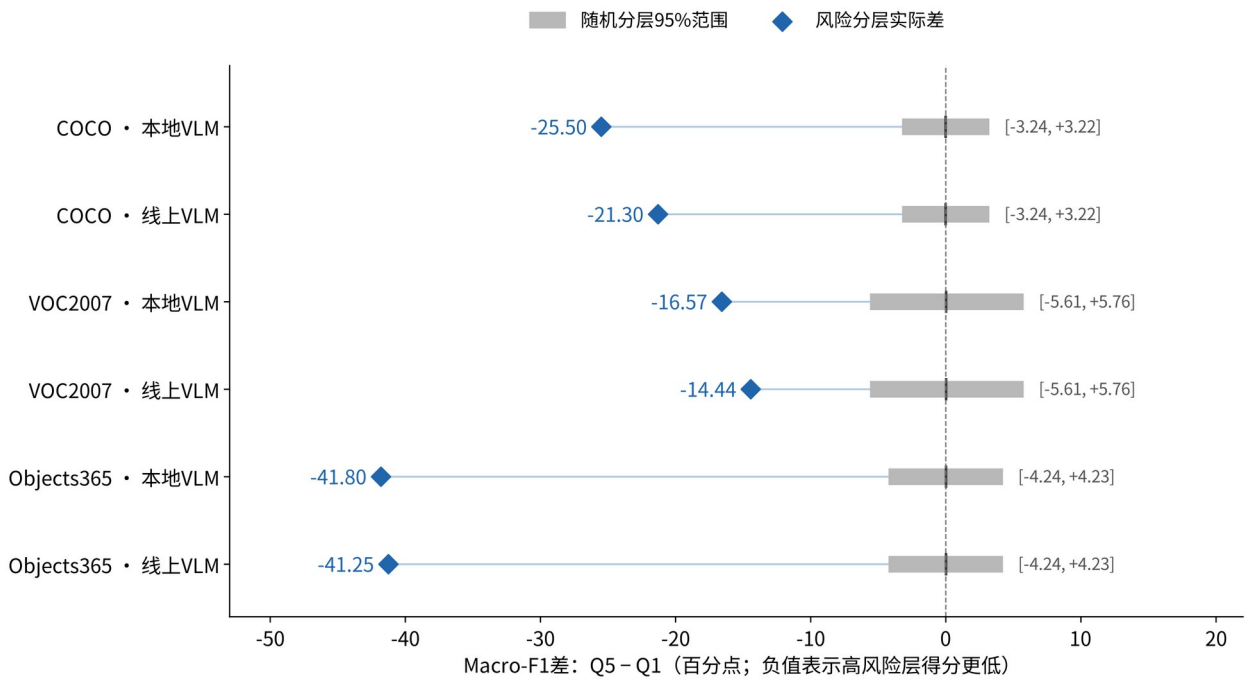


图 4 蓝色菱形为实际风险分层 Q5−Q1；灰色条为固定池中随机划层的中央 95%范围。

怎么看图

先看零线：随机分组差异在零附近波动。再看蓝色菱形：实际风险落差明显更负。COCO 随机范围为−3.24 至+3.22 个百分点，实际落差约−21 至−25 个百分点。

三个池各 10000 次随机划层，没有达到实际落差的绝对值；六项 Holm 校正 p 约 0.00060。这个范围描述随机分组波动，不是部署性能置信区间，也不证明评分最优。

可以这样向老师讲

> 为了检查分层是否只是分组偶然性，我在每个类别内随机打乱并等分五层，重复一万次。随机落差基本围绕零，而真实风险层落差明显更大。这支持风险规则提供了与模型表现有关的分组信息。

接下来追问：这种差异是不是必须依赖某一个风险字段?

05 结果是否过度依赖某一项风险字段?

逐项删除字段，重新评分并重新划层

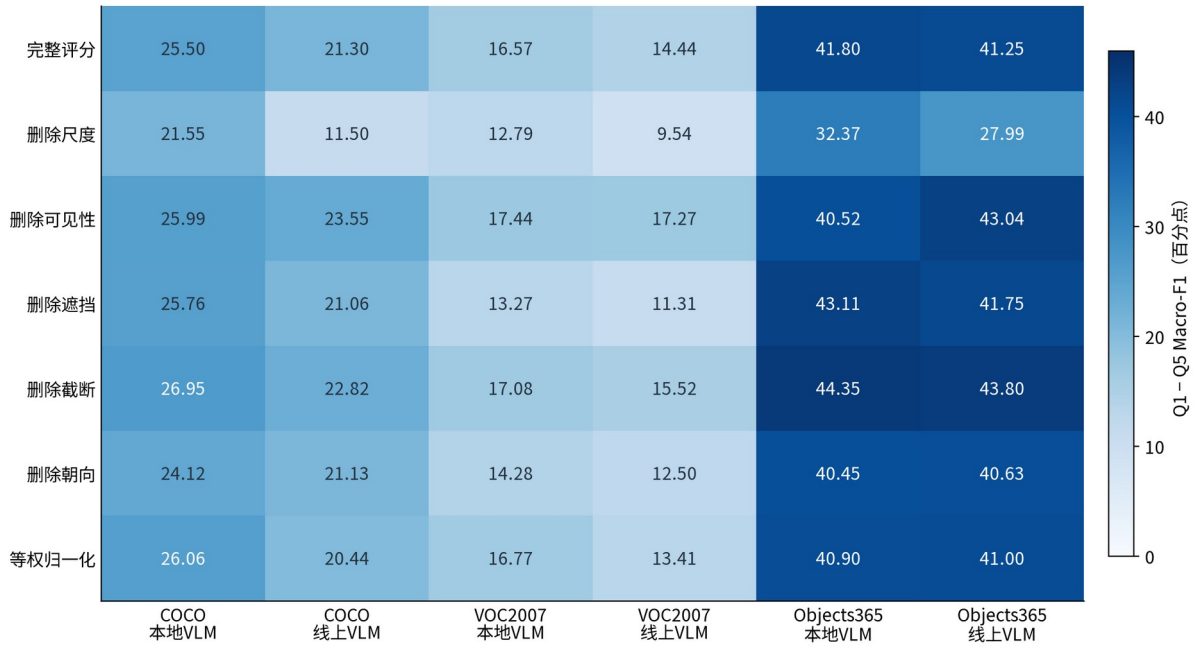


图 5 颜色与数字均表示 Q1−Q5 F1 差；所有变体保持正差，即 Q5 得分较低。

怎么看图

先读完整评分一行，再向下看删除某项后的落差。Objects365 删除尺度后，落差从 41.80/41.25 缩小到 32.37/27.99 个百分点；删除遮挡后仍保留明显差异。

各池消融检验的 Holm 校正 p 为 0.09375，未达到显著标准。这里支持方向保留，不能把删维前后变化解释为单维独立因果贡献，也不能据此验证标签准确率。

可以这样向老师讲

> 我逐项去掉五个风险字段重新划层，检查结果是否依赖某个字段存在。高风险层较低的方向仍保留，尺度在部分来源中的影响较大。不过字段可能相关，成员也改变，所以我保留消融的不确定性。

接下来追问：累计测试中数量和条件同时改变，能不能把数量固定再看?

06 数量不变，风险构成会怎样影响评分？

每次 120 目标，六类各 20 个；21 个真实比例点，每点 1000 次抽样

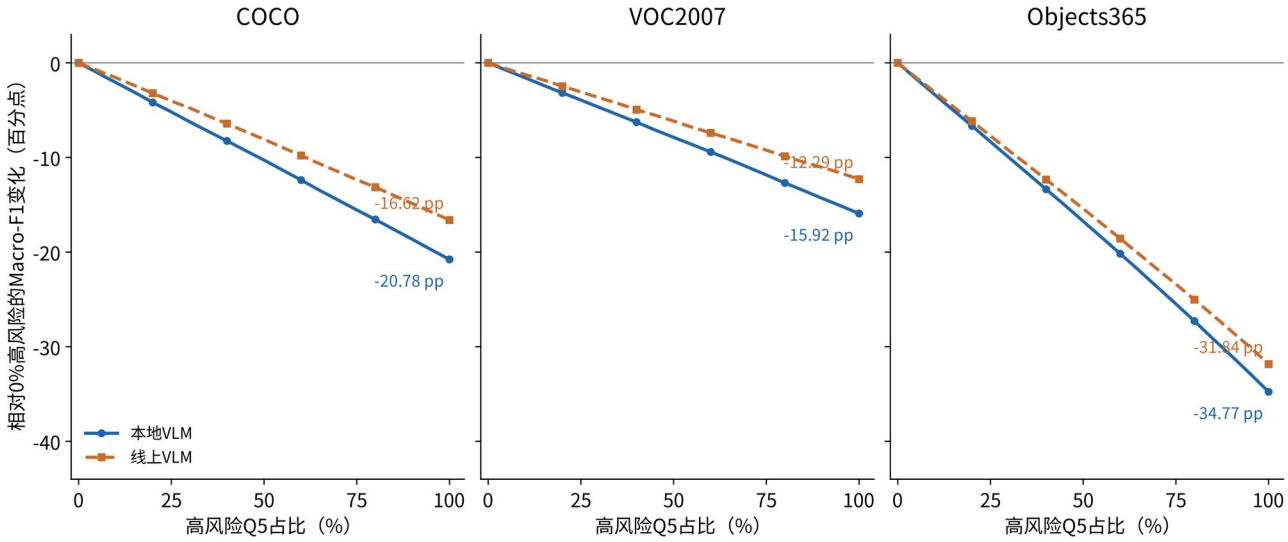


图 6 相对 0% Q5 起点的平均 F1 变化；每条线连接 21 个实测比例点，没有插入新的观测。

来源	本地 100%−0% Q5	线上 100%−0% Q5
COCO	−20.78 个百分点	−16.62 个百分点
VOC2007	−15.92 个百分点	−12.29 个百分点
Objects365	−34.77 个百分点	−31.84 个百分点

怎么看图

横轴是高风险 Q5 占比，纵轴是相对起点的 F1 变化。测试量和类别比例固定，改变的只有成员与风险构成。0%来自 Q1—Q4 混合，不是单独 Q1。

可以这样向老师讲

> 我每次保持一百二十个目标和六类比例，只提高其中高风险目标的比例。总体 F1 终点下降约十二到三十五个百分点，部分模型名次也改变。这说明模型总分需要结合测试构成解释。模型没有继续训练，变化的是测得能力。

覆盖描述测到了哪些状态及证据量；风险构成描述相对高风险目标占比。此实验不能解释为“覆盖率提高导致 F1 下降”。

07 最新对照：只按目标大小分层是否就够了？

连续官方框面积对照，不使用 VLM 状态；与完整评分保持同等配额

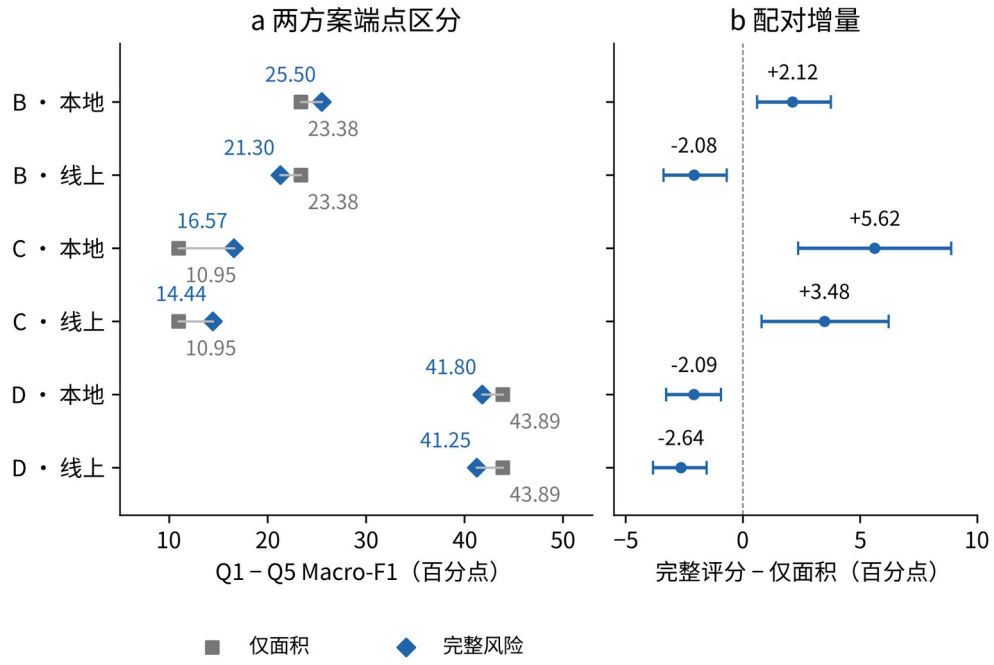


图 7 B=COCO、C=VOC2007、D=Objects365。右图为完整减面积的差；区间按架构/种子重抽。

怎么看图

左图两方案都能形成较大落差；右图看零线两侧，完整评分的增量并非都为正。COCO 本地+2.12、线上−2.08；VOC 本地+5.62、线上+3.48；Objects365 为−2.09/−2.64 个百分点。

完整评分的正增量均未通过六项 Holm 校正；Objects365 面积方案更强的两项校正 p 为 0.04688。不能仅靠更大的高低层差证明 VLM 必要。

可以这样向老师讲

> 最新我增加了只按目标大小分层的简单对照。它本身就很强，多维评分没有普遍更好的端点区分。因此我进一步把状态信息的用途落到条件描述和诊断：它能否在相近粗尺度构成下仍指出薄弱条件？

“删除尺度”检查其他字段是否仍能区分；“只用尺度”检查便宜元数据本身能做到什么。这是两个不同问题。

08 在粗尺度调整后，还有条件诊断信息吗?

沿用冻结假设，排除纯尺度条件；每类按面积五分位进行比较

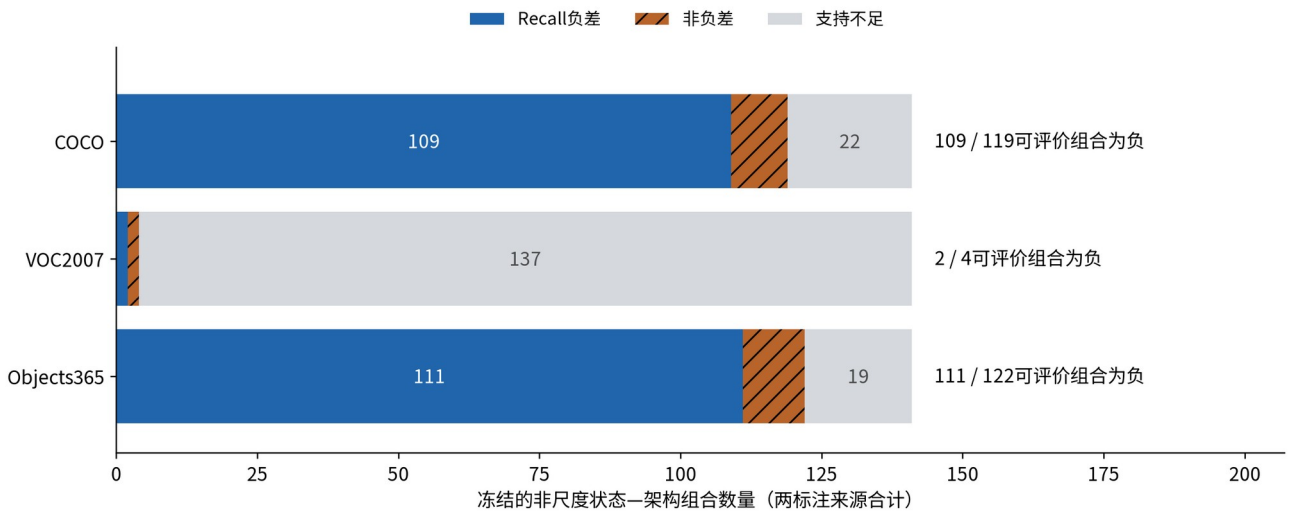


图 8 每池 141 条冻结非尺度组合；蓝色为负差、橙色为非负差、灰色为支持不足。

池	可评价	负差	非负差	支持不足
COCO	119	109	10	22
VOC2007	4	2	2	137
Objects365	122	111	11	19

怎么看图

COCO 和 Objects365 多数可评价组合仍为负差，VOC 主要是灰色支持不足。支持不足不等于没有风险；负差计数是重叠组合的描述性结果，不是独立缺陷数量。

可以这样向老师讲

> 我在每个类别的面积五分位层中，比较某状态与同字段的已知非状态，并按支持量加权。COCO119 个可评价组合中 109 个为负，Objects365122 个中 111 个为负。这支持许多状态在粗尺度调整后仍有诊断关联。VOC 只有四个可评价，不能概括为稳定复现。

面积五分位不等于连续面积精确匹配，其他条件也可能共现。因此当前结果是关联证据，不能认定某状态导致分类错误。

09 用真实案例把状态、输入和预测连起来

原图上下文、分类器实际裁剪输入与自动标签的用途不同



图 9 四个既有条件的真实目标和实际输入；前三例按三种子均错、第四例按均对的规则选择。

这组案例用于解释测试流程，不估计总体失败比例，也不是人工语义复核。Resize 与中心裁剪可能丢失细长目标的信息，结果描述的是分类器加预处理流程。

可以这样向老师讲

> 我还补了实际输入案例，帮助理解模型到底看到了什么。状态标注可以看到原图上下文，但分类器使用固定裁剪输入。因此错误不能全部归因于架构或某个状态，预处理也属于测试对象的一部分。

10 现在可以向老师明确交代的成果和边界

研究定位：自动视觉状态测试与条件诊断的实证研究

已经完成	带来的证据或用途
五层测试与三池确认	风险层能揭示总体指标掩盖的条件差异
冻结薄弱条件确认	支持充分的新来源可提供后续测试需求
随机划层、删维和风险混合	检查分组波动、字段依赖及测试构成响应
仅面积与面积层内对照	限定多维评分优势，明确条件诊断用途
中英文论文、图表与补充材料	最新结果和结论边界已经同步
便携缓存复算	已有独立复算记录：8 张新表、60 项历史比较一致

汇报中必须保留的边界

1. 分类真值来自数据集；自动状态没有完整人工语义真值。双 VLM 一致不等于正确。
2. 条件差是关联，不是因果根源；面积调整没有控制所有混杂。
3. Coverage 收益具有条件性，没有证明普遍超过强基线。
4. 重复抽样不是新增数据，三个种子不是三个独立架构。
5. 缓存复算不等于从零重跑训练、VLM 调用和原始聚类。

可以这样向老师讲

> 这一阶段我按照您的建议完成了分层，又通过新样本、新来源和多种对照明确了它的作用。最有用的成果是把总体表现展开为可复用的条件报告，帮助指定进一步测试。论文和复算材料已更新，接下来重点是审阅贡献表述和完善投稿材料。

建议带到组会的材料

主讲本报告 01—08 节及第 10 节；真实案例、标签敏感性和 Coverage 基线放备用材料。最新论文：docs/论文_最新.docx；完整材料包：docs/visual_state_testing_submission_materials_20261007.zip。

附录 A 可直接讲的连贯汇报稿

约 5—7 分钟；不需要逐个念全部数字

老师，上次您建议我对测试数据做分层。这一阶段我先落实了这个建议，再围绕分层结果做了一系列验证。

首先，我使用目标大小、身体可见性、遮挡、截断和朝向五个维度，在每个类别内部划分五个等数量风险层。分层不读取分类器是否答错，分类真值来自数据集，状态由程序和两套 VLM 提供。模型训练完成后保持冻结，所以后续指标变化反映测试条件变化。

初步结果发现，高风险层的 F1 低于低风险层。为检查这是不是原样本的特殊现象，我固定分层规则，在新的 COCO 样本、VOC 和 Objects365 中确认。三个确认池共五千四百个目标，六类均衡，八种架构各三个种子。结果在这些来源中重复出现，高低风险层的平均 F1 相差约十四到四十二个百分点。

接着，我把整体分层往具体状态诊断推进。比如 ResNet-50 的 dog 总体 Recall 约百分之八十二，但背向 dog 约百分之五十七。这样的报告能指出下一步该测什么。我在发现池冻结薄弱条件，再到新池确认。COCO 和 Objects365 支持充分时，多数条件保留薄弱方向；VOC 很多状态样本太少，具体迁移证据有限。

为了检查分层是否只是分组偶然性，我每池做了一万次类别平衡随机划层。随机差围绕零波动，明显小于实际风险层落差。我也逐项删除风险字段重新划层，高风险层较低的方向仍保留，但没有把消融解释成各字段的独立因果贡献。

然后我固定测试总量和类别比例，只改变高风险目标占比。每次一百二十个目标、六类各二十个，共二十一个比例点。即使数量不变，风险构成变化仍对应平均 F1 下降约十二到三十五个百分点，部分模型名次也改变。这说明模型总分需要附带测试条件解释，不能把下降理解成模型训练后退化。

最新我增加了只按目标大小分层的对照。这个简单方法也能形成很强的区分，多维评分没有普遍更强。因此我进一步检查尺度之外的条件信息。在粗面积层内比较后，COCO 一百一十九个可评价组合中一百零九个仍有 Recall 负差，Objects365 一百二十二个中一百一十一个为负。这支持状态报告用于条件诊断，但不证明因果根源或全部自动标签正确。

目前的成果是：完成了风险分层，并通过新样本、新来源、随机和尺度对照明确了它的用途；把总体表现展开为可复用的薄弱条件报告。最新论文和复算材料已同步整理，接下来重点是审阅贡献表述和完善投稿材料。

附录 B 老师可能追问什么?

先回答具体问题，再说明证据范围

你比上次多做了什么?

分层落实了上次建议。后续新增新样本/来源确认、冻结状态确认、随机与删维检查、固定预算混合，以及最新面积单独对照和面积层内诊断。

F1 下降为什么算进展?

进展在于发现并确认条件能力差异。冻结模型面对不同图片时测得分数改变；F1 下降本身不能证明测试更好。

只按大小就能分层，VLM 有什么用途?

仅要端点区分时，面积很强。状态提供更具体的条件描述和可复用测试需求；当前未证明其成本效益普遍更好。

你找到了模型错误原因吗?

发现的是关联的薄弱条件。状态会共现，尺度调整不完整，裁剪也会影响输入；没有隔离因果根源。

状态标签可靠吗?

已做官方部分属性参考、双 VLM 分歧和敏感性分析，没有完整人工真值。结论限定在自动协议下。

覆盖和风险有什么不同?

覆盖表示测到了哪些状态及证据量；风险表示预定义困难条件的构成。更多错误也不自动等于更多不同失败。

附录 C 数值与图表的来源

本报告复用既有实验；没有新增训练、推理或 VLM 标注

内容	本工作目录下的证据
初始五层	sixclass_difficulty_supplement_20261004/tables/full_stratum_metrics.csv
三池确认与随机	random_stratification_ablation_20261006/tables/random_summary.csv；ablation/*.npz
具体条件案例	论文_最新.md 表 10—11；submission_closeout_20261007/figures/04_condition_cases.svg
逐项删维	random_stratification_ablation_20261006/tables/ablation_summary.csv
固定 120 目标风险混合	controlled_risk_distribution_20261005/tables/panel_summary.csv、distribution_contrasts.csv
连续面积对照	scale_only_confirmation_20261007/tables/summary.csv
粗尺度内条件	scale_only_confirmation_20261007/tables/area_condition_summary.csv
已有独立复算记录	submission_closeout_20261007/portable_replay_audit.json

上表未另写前缀的实验路径位于 artifacts/；论文位于 docs/。汇报起点“老师建议分层”依据用户回忆，其余工作依据聊天与结果文件，不推定为老师逐项要求。

口径提醒：Macro-F1 是六类 F1 等权平均；表中的 pp/百分点不是相对百分比。Q1–Q5 是完整层比较；100%–0%风险混合是另一实验，0%来自 Q1—Q4。自动属性对齐 F1 也不能当作分类 F1。

图表编辑：材料包保留 SVG、PNG 与生成脚本。图中的数值直接来自保存结果；统计范围与适用边界在每页图注中说明。