视觉状态驱动模型测试：阶段性结果汇报

截至 2026 年 10 月 12 日｜研究定位：模型测试与条件诊断的实证研究

研究问题与已完成实验

研究问题：除了总体分类分数，能否利用自动视觉状态，更有针对性地选择测试样本，并指出模型在哪些条件下表现薄弱？

实际流程为：目标图像 → 自动视觉状态描述 → 覆盖引导选样／风险分层测试 → 条件能力报告 → 新目标复查。官方类别标签判断分类对错，VLM 描述视觉条件，被测分类模型提供预测。

已完成 dog、cat、horse、sheep、person、car 六类目标区域分类实验。主实验包含 8 种分类架构（含 ResNet、MobileNet、ConvNeXt、Swin 等），每种 3 个训练种子，共 24 次模型运行；新目标确认使用 COCO、VOC2007、Objects365 三个数据池，共 5,400 个目标。本地与线上 VLM 状态标注分别分析。

结果一：同样的测试数量，获得更多视觉状态支持

Coverage 优先选择包含稀缺视觉状态的目标；Random 在相同类别和风险配额内随机选样。下表取各池最大测试预算点。

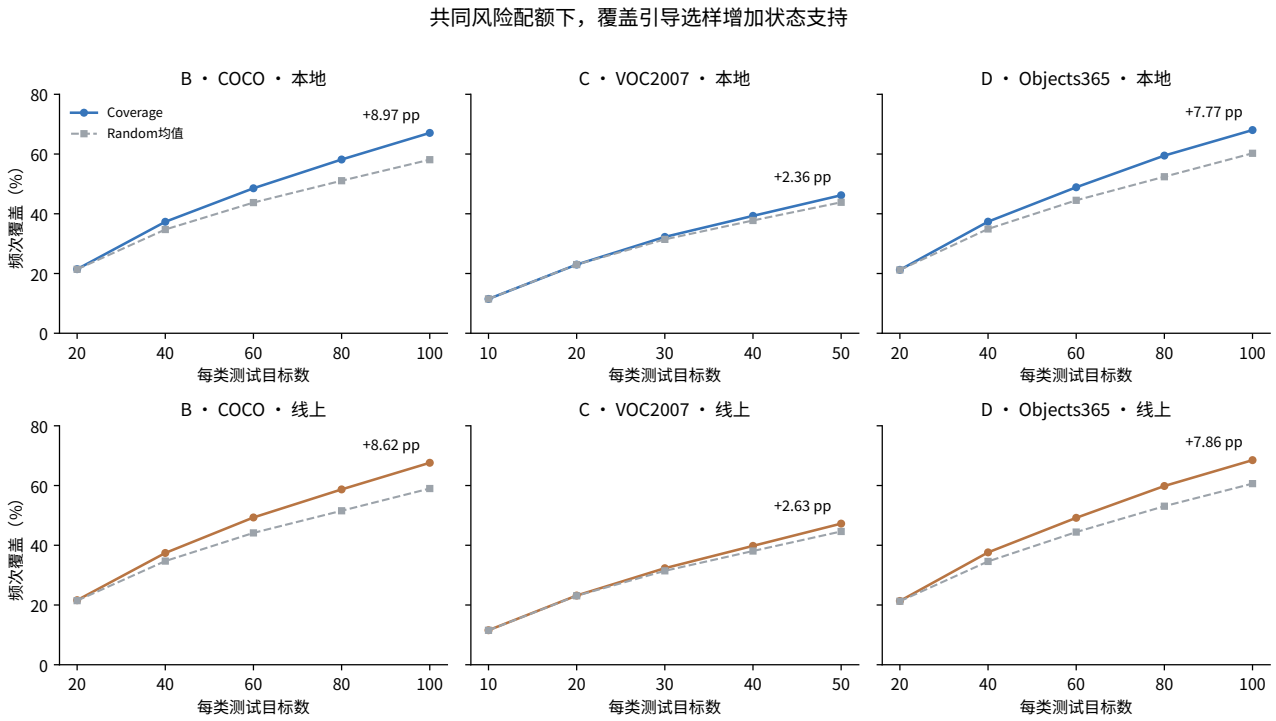


图 1 覆盖引导选样与随机选样的状态覆盖比较

图 1 说明：蓝色为本地状态来源，橙色为线上来源；实线为 Coverage，虚线为 Random。两种来源分别组织测试。各池状态词表不同，覆盖值用于同池比较。

确认数据池	测试目标数	本地覆盖增量	线上覆盖增量
COCO 新目标	600	+8.97 个百分点	+8.62 个百分点
VOC2007	300	+2.36 个百分点	+2.63 个百分点
Objects365	600	+7.77 个百分点	+7.86 个百分点

结果含义：相同测试数量下，预定义视觉状态的频次支持更充分。最大预算点的增量为 2.36—8.97 个百分点；这不是分类准确率提升，也不保证所有预算点均占优。

结果二：测试构成会明显改变同一模型的测得性能

依据目标尺度、可见性、遮挡、截断和朝向等条件，将目标分为五个风险层，Q5 为最高风险层。每次测试固定 120 个目标、每类 20 个，仅改变 Q5 目标占比；模型权重不变。

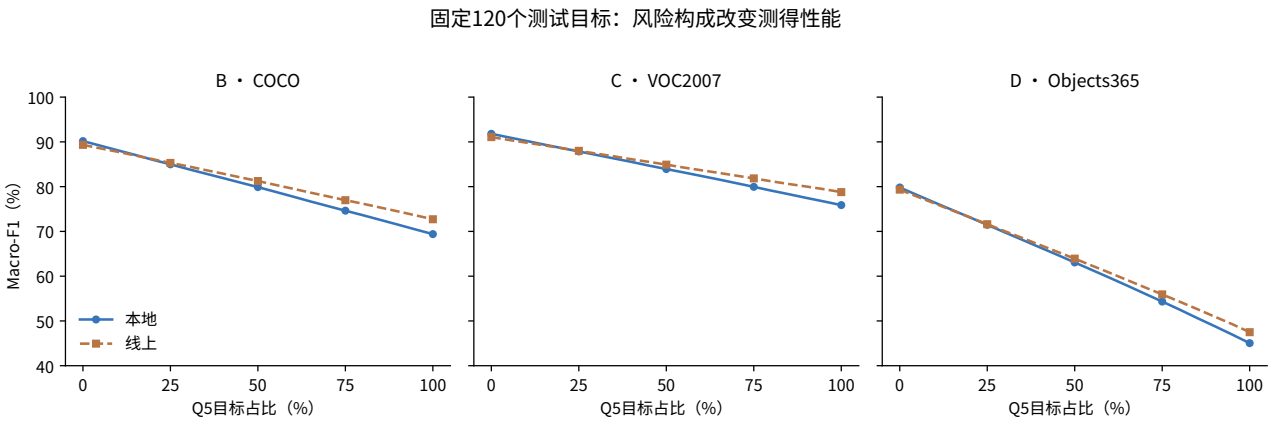


图 2 固定测试数量下的高风险样本占比与模型表现

图 2 说明：横轴为 Q5 目标占比，纵轴为主实验模型的平均 Macro-F1。0% 从 Q1—Q4 并集抽样，100% 全部从 Q5 抽样；每个比例重复抽样 1000 次，两条线对应两种状态来源。

确认数据池	本地：Q5 占比 0% → 100%	线上：Q5 占比 0% → 100%
COCO 新目标	90.18% → 69.40%	89.34% → 72.72%
VOC2007	91.80% → 75.88%	91.07% → 78.78%
Objects365	79.81% → 45.04%	79.33% → 47.49%

结果含义：六个“数据池—状态来源”设置的平均 Macro-F1 降低 12.29—34.77 个百分点。变化来自测试样本构成，说明总体分数需要结合所测试的视觉条件解释；不能将其理解为模型训练后变差。

随机对照与模型扩展

主实验的高低风险层性能落差超出类别平衡随机划层的波动。另在 5 种架构、每种 3 个种子的扩展实验中，30 个“模型—数据池—状态来源”平均高低风险层落差均为正，范围为 14.92—42.01 个百分点，保留了同方向的条件差异。扩展结果只说明高、低层端点差，不表示中间层严格逐层下降；扩展组未重复随机划层和仅面积对照。

覆盖增加是否带来更多诊断信息？

在控制风险构成和错误数量后，覆盖选样在部分检验设置下，比随机选样获得更广的混淆类型与错误表征簇信息；该优势未在所有控制协议下成立，也未获得普遍超过强基线的证据。完整风险评分亦未表现出相对仅目标面积分层的普遍优势。

因此，当前最稳定的发现是：视觉条件能揭示总体指标掩盖的性能差异；覆盖选样的额外诊断收益具有适用条件。

结果三：从总体指标得到具体、可复查的薄弱条件

条件能力报告同时列出“类别总体 Recall”和“某视觉状态下的 Recall”，把总体分数转为明确的后续测试对象。Recall 表示该类真实目标中被正确识别的比例。

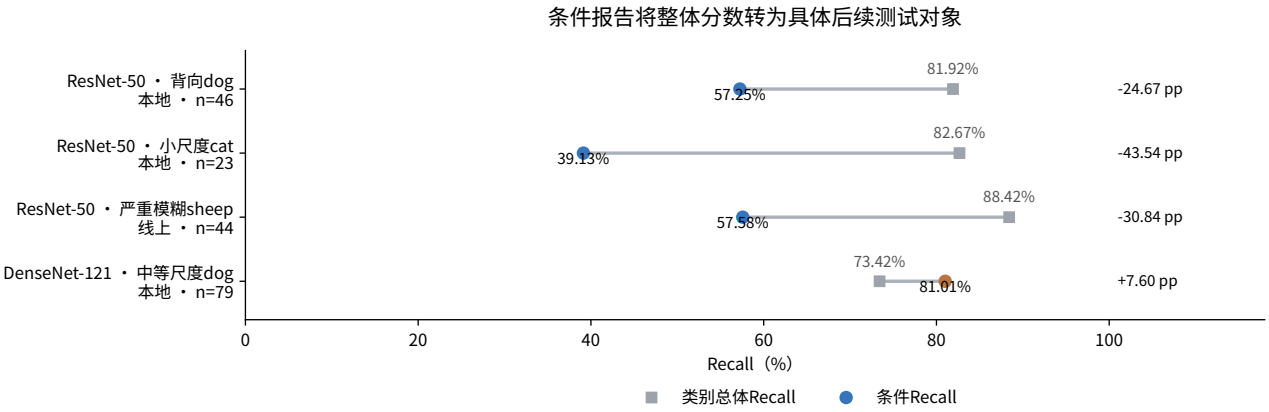


图 3 类别总体表现与具体视觉条件表现的对比

图 3 说明：案例来自 COCO 新目标池，分数为三个种子均值，n 为目标数。方块为类别总体 Recall，圆点为条件 Recall；同时保留表现回升的条件。

例如，ResNet-50 的 dog 总体 Recall 为 81.92%，背向 dog 仅为 57.25%（46 个目标），相差 24.67 个百分点。这给出了明确的测试线索：继续检查背向 dog，而不只是报告 dog 总体识别率。DenseNet-121 的中等尺度 dog 则为 81.01%，高于该类总体 73.42%，说明既有薄弱条件并非全部延续。

新目标复查结果

沿用发现阶段的 175 个“状态来源—模型—类别—视觉状态”候选组合。新目标中的支持数达到 20 后，比较三种子平均条件 Recall 与类别总体 Recall。

确认数据池	可评价组合	平均 Recall 仍低于类别总体	支持不足组合
COCO 新目标（同来源）	153	138	22
VOC2007（外部来源）	4	2	171
Objects365（外部来源）	160	142	15

COCO 与 Objects365 中，支持充分的候选组合多数仍保留薄弱方向。VOC2007 多数条件缺少足够目标，暂不能判断整体迁移。这些是共享模型与重叠状态的描述性组合计数，不代表逐项显著或彼此独立的复现。

当前结论与研究价值

当前结果支持：自动视觉状态可用于组织模型测试、补充总体分类指标，并形成可在新目标中继续检查的薄弱条件。方法的输出是状态支持记录、条件能力报告与后续测试线索。

实证贡献主要在于：将视觉状态用于测试选样；展示测试构成对测得性能的影响；用新目标检查既有条件诊断。现有结果尚未证明模型准确率提高，也不支持把状态关联解释为错误的因果根源。

数据依据：已完成实验的原始分类预测与汇总表；图表与数值对应《当前方法实证结论与结果图 _20261012》。本简报仅压缩已有结果，未增加训练或 VLM 请求。