视觉状态驱动测试：模型之间有什么区别?

教师汇报版｜ 2026 年 10 月 12 日｜ 8 种主模型＋ 5 种独立扩展模型

一、先看模型总体表现，再看被总体分数掩盖的差异

本报告将模型作为比较对象，统一使用 COCO 新目标确认池的 2,400 个目标、同一本地视觉状态标注及同一风险分层。任务为 dog、cat、horse、sheep、person、car 六类别目标区域分类；主实验每种模型保留 3 个训练种子。

研究方法的作用是：用覆盖选样增加状态支持，用风险分层揭示条件差异，再把模型结果写成可复查的条件报告。以下各图使用相同模型顺序，分数为三种子均值；百分比表示成绩，百分点表示差值。SD 为三个训练种子的样本标准差，表示训练波动。

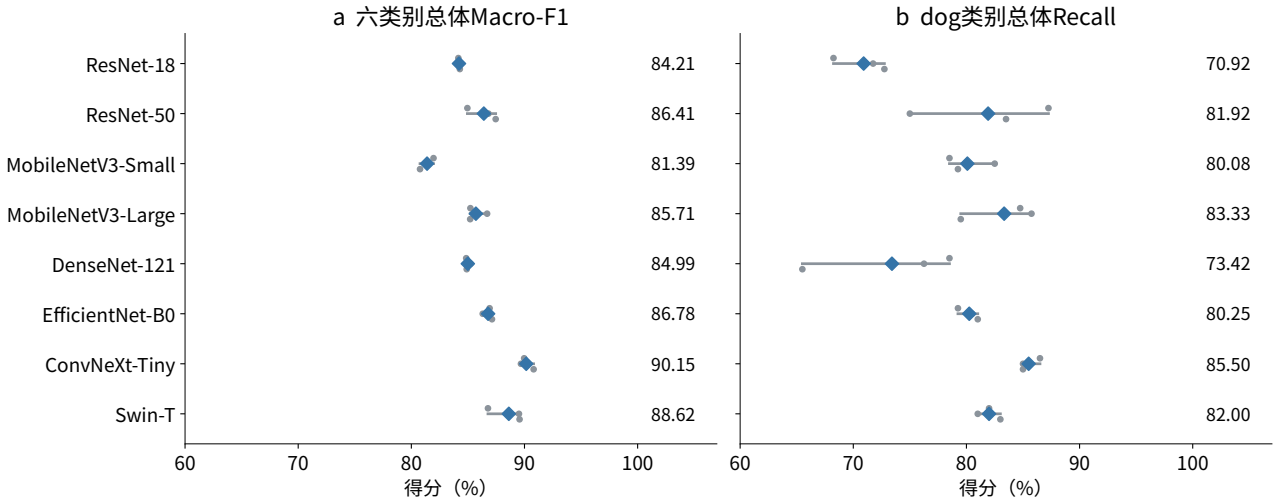


图 1 相同目标上的模型总体表现与 dog 类别表现

图 1 说明：菱形为均值，灰点为三个种子，灰线为最小—最大范围；不是置信区间。总体 F1 在完整 2,400 目标上直接计算，不是五个风险层 F1 的简单平均。

模型	全池 F1：均值 ±SD	Q5 F1	Q1−Q5 落差
ResNet-18	84.21±0.07%	67.97%	26.81 个百分点
ResNet-50	86.41±1.30%	70.02%	26.44 个百分点
MobileNetV3-Small	81.39±0.60%	64.67%	24.63 个百分点
MobileNetV3-Large	85.71±0.86%	68.77%	25.76 个百分点
DenseNet-121	84.99±0.21%	66.13%	30.17 个百分点
EfficientNet-B0	86.78±0.43%	70.66%	24.76 个百分点
ConvNeXt-Tiny	90.15±0.58%	74.97%	22.73 个百分点
Swin-T	88.62±1.60%	73.73%	22.66 个百分点

当前数值比较中，ConvNeXt-Tiny 的总体 F1 为 90.15%，高风险 Q5 为 74.97%，均为主组最高。Swin-T 次之。该排序限于本任务与实际训练设置，未进行逐对模型优劣显著性检验。

二、覆盖提高以后，对不同模型的测试有何作用?

相同 600 个测试目标预算下，Coverage 频次覆盖为 67.07%，Random 为 58.11%，增加 8.97 个百分点。八个模型共用选样结果，因此覆盖率相同；真正需要逐模型比较的是增加覆盖后得到的诊断信息。

在相同类别和风险配额内，再匹配各类错误数量，比较 Coverage 与 Random 覆盖的混淆类型和错误表征簇。这样可检查“不是仅仅因为错误更多，是否仍能得到更广的失败信息”。

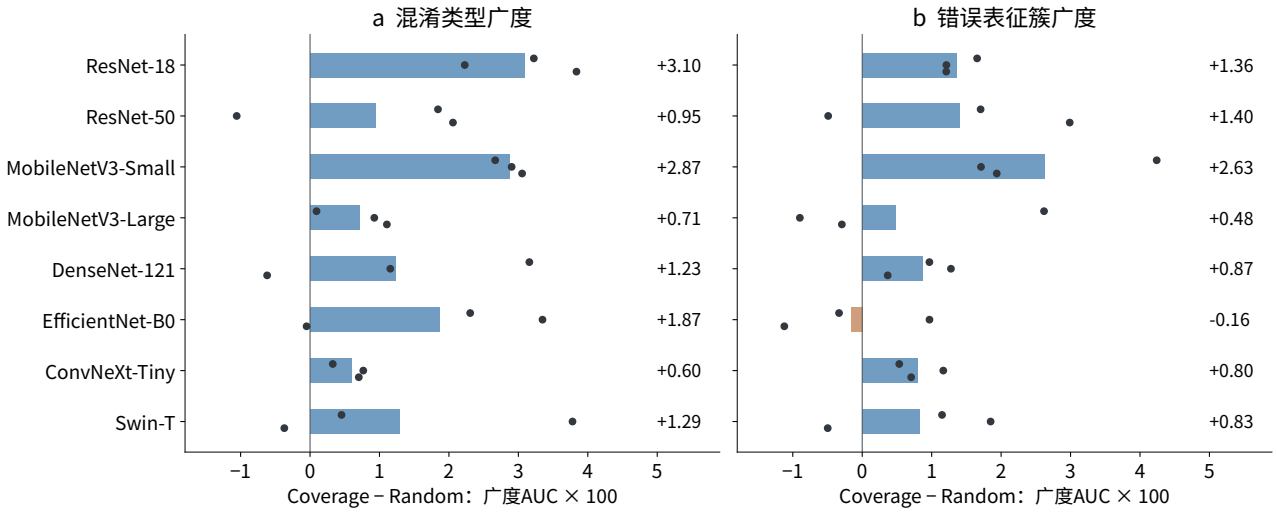


图 2 覆盖选样相对随机选样的逐模型诊断增量

图 2 说明：柱为三种子平均增量，黑点为逐种子结果；零线右侧有利于 Coverage。数值为标准化预算 AUC 的差 ×100，即曲线积分除以最大预算 100 后比较；不是分类 F1 或 ROC-AUC。预算为每类 20—100 个目标，包含零预算零广度起点。

模型	混淆广度增量 ×100	表征簇广度增量 ×100	正增益种子：混淆／簇
ResNet-18	+3.096	+1.359	3/3 ／ 3/3
ResNet-50	+0.948	+1.401	2/3 ／ 2/3
MobileNetV3-Small	+2.875	+2.629	3/3 ／ 3/3
MobileNetV3-Large	+0.709	+0.476	3/3 ／ 1/3
DenseNet-121	+1.232	+0.871	2/3 ／ 3/3
EfficientNet-B0	+1.868	-0.162	2/3 ／ 1/3
ConvNeXt-Tiny	+0.599	+0.802	3/3 ／ 3/3
Swin-T	+1.288	+0.834	2/3 ／ 2/3

混淆类型广度的平均增量在 8 个模型上均为正；表征簇广度在 7 个模型上为正。 MobileNetV3-Small 两项均为 3/3 种子正增量；EfficientNet-B0 的表征簇平均增量为负，必须保留这一结果。

可以向老师解释：“同样提高了测试状态覆盖，对不同模型带来的诊断收益并不相同。”表征簇及其分母随模型变化，应比较模型内部 Coverage−Random 的差；本图不用于模型能力排名，也未给单个模型做显著性声明。现有结果未支持全面优于强基线。

三、相同风险层下，各模型的表现如何变化？

风险规则根据尺度、可见性、遮挡、截断和朝向等条件分为 Q1—Q5。Q1 为低风险层，Q5 为高风险层；每层 480 个目标、六类别各 80 个。所有模型使用完全相同的层成员。

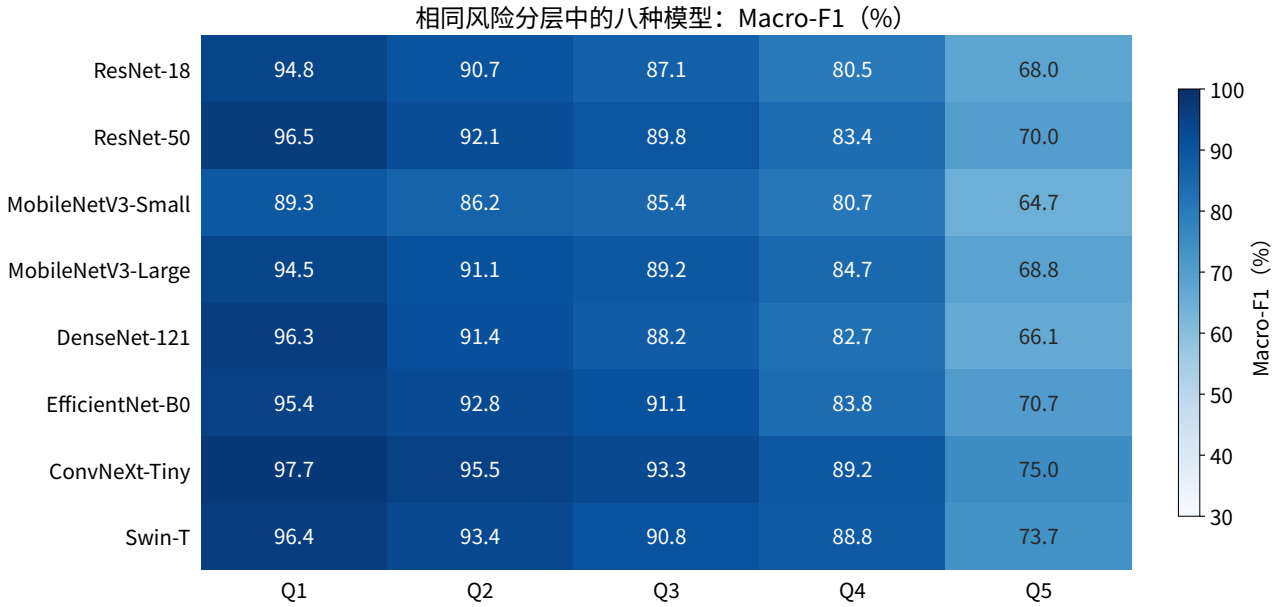


图 3 八种模型在五个共同风险层中的表现

图 3 说明：每行是模型，每列是风险层，格内数值为三种子平均 Macro-F1（%）。颜色越深，分类表现越好。分层依据不使用被测分类器的预测或错误。

模型	Q2 F1	Q3 F1	Q4 F1
ResNet-18	90.65%	87.12%	80.47%
ResNet-50	92.15%	89.78%	83.42%
MobileNetV3-Small	86.21%	85.36%	80.73%
MobileNetV3-Large	91.11%	89.21%	84.70%
DenseNet-121	91.35%	88.24%	82.67%
EfficientNet-B0	92.80%	91.12%	83.78%
ConvNeXt-Tiny	95.50%	93.32%	89.17%
Swin-T	93.36%	90.81%	88.76%

分层把总体指标展开成模型的条件表现。例如 DenseNet-121 的总体 F1 为 84.99%，高于 ResNet-18 的 84.21%；但 Q5 中前者为 66.13%，后者为 67.97%。总体次序在高风险条件中发生了变化。

可以向老师解释：“总体分数只能说明平均表现，分层能指出模型在何种目标上失去优势。”本设置的层均值下降不构成普遍单调规律；完整风险评分也未普遍强于仅用目标面积分层。

四、比较高风险绝对表现与高低风险落差

仅看 Q1−Q5 的下降幅度容易误判：两层都低的模型，也可能下降较少。因此同时看 Q5 实际分数和层间落差。

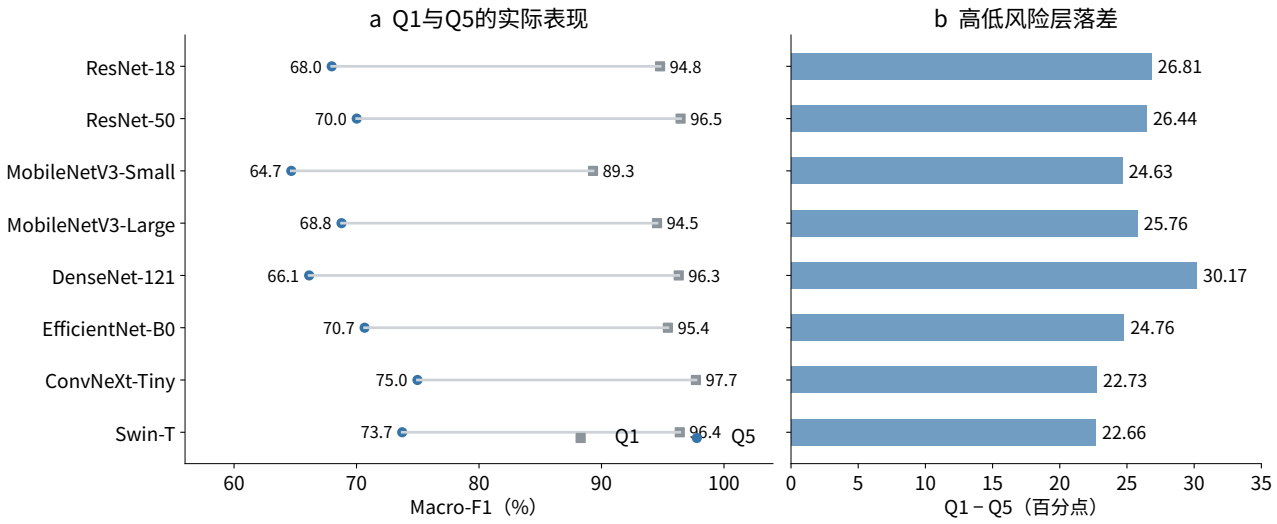


图 4 各模型的高风险成绩与高低风险落差

图 4 说明：左图灰方块为 Q1、蓝圆点为 Q5，连线表示高低层成绩跨度；右图为 Q1−Q5 的差值。两边均为三种子均值，不能将落差更小自动解释为模型更强。

MobileNetV3-Small 的层间落差为 24.63 个百分点，Q5 为 64.67%；ConvNeXt-Tiny 落差为 22.73 个百分点，Q5 为 74.97%。后者在高风险目标上的实际成绩更高。

DenseNet-121 的落差为 30.17 个百分点，是本主组最大值；它的 Q1 成绩较高，但 Q5 优势未保留。ResNet-50 相对 ResNet-18 则在总体与 Q5 中都取得较高均值。

该比较回答的是“哪些模型在相同视觉条件下更容易暴露性能不足”，而不是给模型建立脱离任务的永久排名。模型侧差异提供了本方法的诊断对象；具体原因仍需另外实验验证。

这一页可以怎样讲?

“我的方法不只是让每个模型得到一个总分，而是同时报告容易条件、困难条件和落差。例如 DenseNet 总体比 ResNet-18 高，但在最高风险层中反而低；这类差别是总体评价容易漏掉的。”

五、测试量固定后，各模型怎样响应高风险占比?

每次固定 120 个目标、六类各 20 个，让 Q5 占比从 0% 增加至 100%。0% 来自 Q1—Q4 并集，100% 来自 Q5；其余比例在这两部分抽样。每个比例重复抽样 1000 次，不重新训练模型。

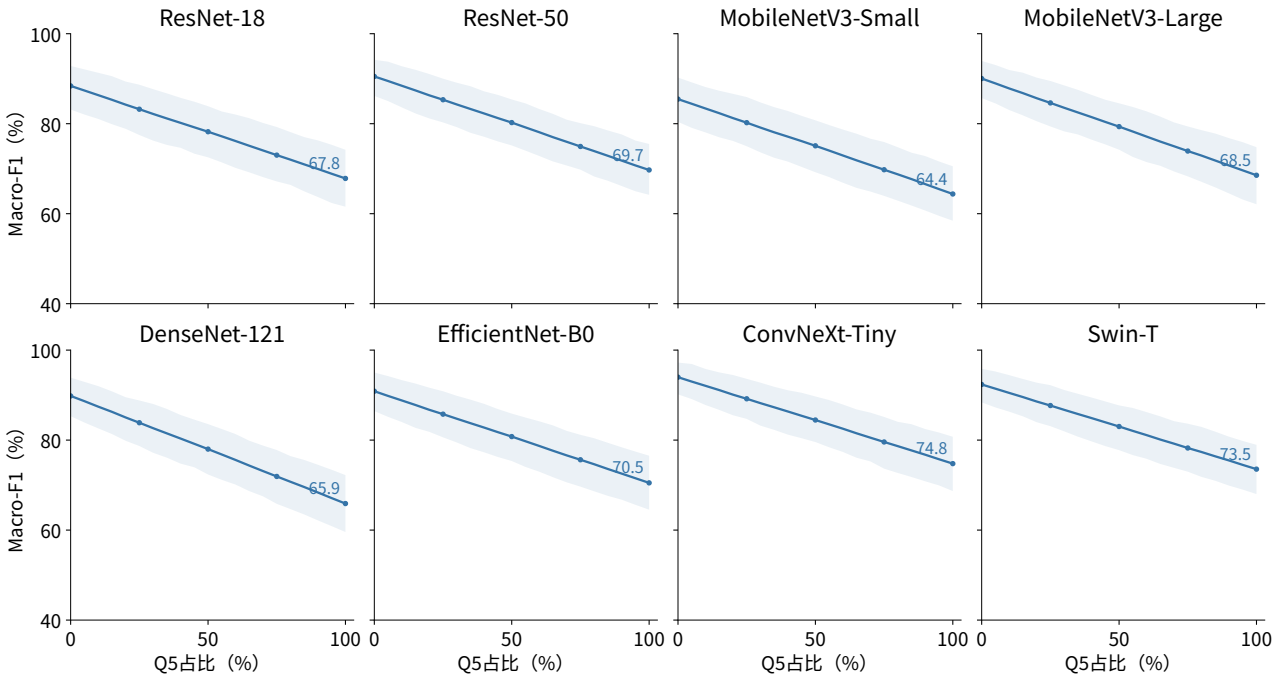


图 5 固定 120 目标时各模型的风险构成响应

图 5 说明：八个小图共用坐标。实线为种子与重复抽样的平均 F1；浅带为当前池内重复抽样的中心 95% 范围，不是新数据性能置信区间。线尾数字为 100% Q5 的平均成绩。

模型	Q5 占比 0%：F1	Q5 占比 100%：F1	变化
ResNet-18	88.40%	67.84%	-20.56 个百分点
ResNet-50	90.50%	69.72%	-20.78 个百分点
MobileNetV3-Small	85.46%	64.38%	-21.08 个百分点
MobileNetV3-Large	90.03%	68.54%	-21.49 个百分点
DenseNet-121	89.81%	65.90%	-23.91 个百分点
EfficientNet-B0	90.87%	70.50%	-20.37 个百分点
ConvNeXt-Tiny	93.98%	74.77%	-19.21 个百分点
Swin-T	92.36%	73.55%	-18.81 个百分点

不同模型随高风险占比上升而呈现不同的成绩水平和端点变化。这里的变化由测试构成产生，说明向老师汇报模型成绩时，需要交代测试了多少高风险目标。

图 5 的 100% Q5 只抽取 120 个目标，图 3 ／ 4 的完整 Q5 使用 480 个目标；二者 F1 不必相等。图中的下降不表示模型训练后退化，也不证明每个类别 Recall 都同步下降。

六、同一种视觉条件，哪些模型更容易识别?

选取背向 dog、小尺度 cat、严重模糊 sheep、中等尺度 dog 四个条件作解释案例。各条件内八模型面对相同目标；条件不是独立错误类型，也不是全面挑选模型优劣的基准。

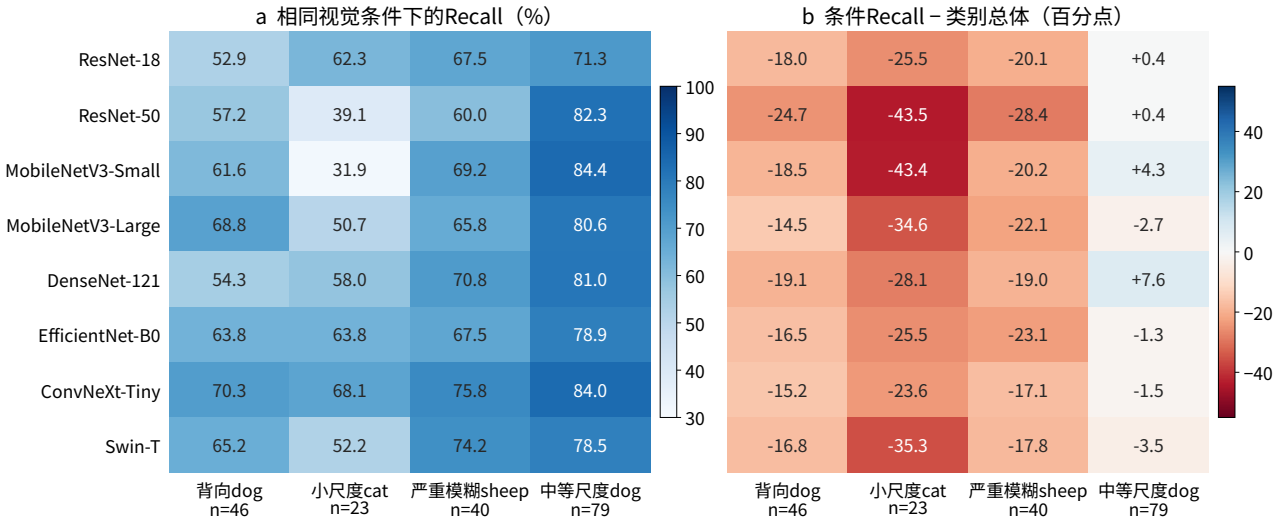


图 6 同一视觉条件下的逐模型 Recall 及相对类别差

图 6 说明：左图为条件 Recall，右图为条件 Recall 减对应类别总体 Recall；右图负数表示该条件较弱，正数表示较强。n 是目标数，所有格为三种子均值；中等尺度 dog 同时保留非负差，避免只展示薄弱案例。

对比条件	ResNet-50 Recall	ConvNeXt-Tiny Recall	同批目标数
背向 dog	57.25%	70.29%	46
小尺度 cat	39.13%	68.12%	23
严重模糊 sheep	60.00%	75.83%	40
中等尺度 dog	82.28%	83.97%	79

在背向 dog 条件中，ResNet-50 的 Recall 为 57.25%，ConvNeXt-Tiny 为 70.29%；在小尺度 cat 条件中，两者又呈现另一组差异。

左图用于相同目标上的模型比较；右图用于解释“这一条件相对该模型自身类别水平是否偏弱”。两种问题需要分开。例如模型条件 Recall 较高，仍可能比它自身类别总体低；不能只凭右图差值排模型强弱。

可以向老师解释：“分层提示哪里表现下降，状态报告进一步指出具体是哪类条件。不同模型在相同条件下的表现不同，所以后续测试能针对模型展开。”这里的关联不证明某个状态单独导致错误。

七、各模型已有薄弱条件在新目标中是否延续?

发现阶段为每个模型形成候选条件清单；本页沿用清单检查新目标。支持数至少 20 时，比较三个种子平均条件 Recall 与类别总体 Recall，并保留平均非负差及支持不足的条件。

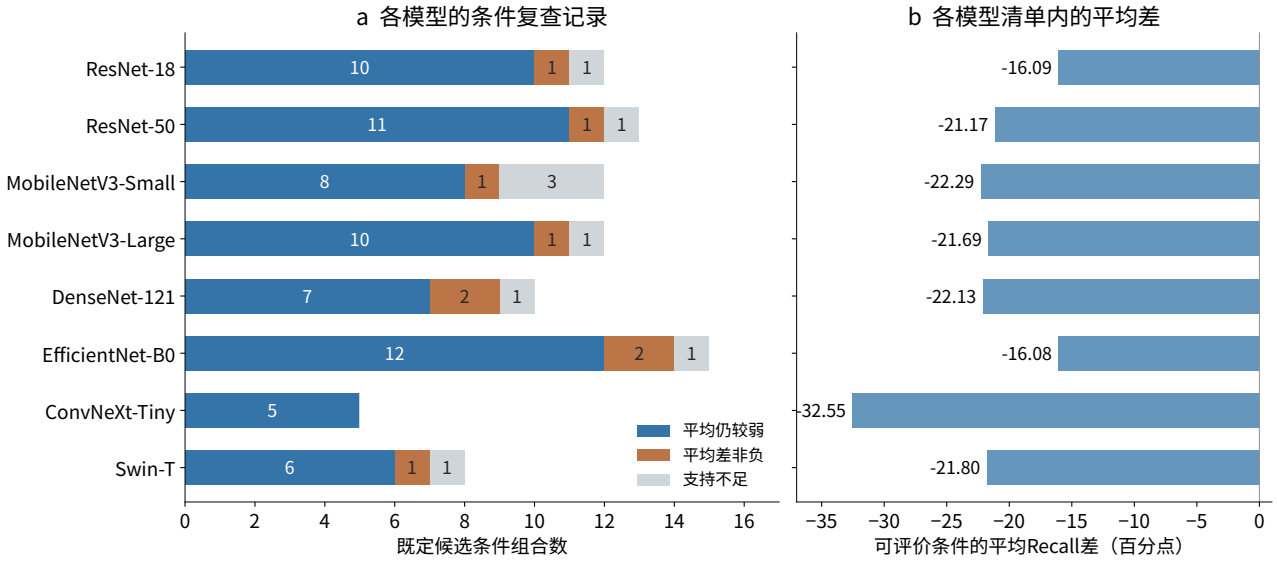


图 7 逐模型的薄弱条件复查记录

图 7 说明：左图把各模型清单分为平均仍较弱、平均差非负、支持不足；右图为各自可评价清单的平均 Recall 差。候选清单不同，右图及组合数量不用于模型优劣排名；计数不是逐项显著或独立复现。

模型	可评价组合	平均仍较弱	支持不足
ResNet-18	11	10	1
ResNet-50	12	11	1
MobileNetV3-Small	9	8	3
MobileNetV3-Large	11	10	1
DenseNet-121	9	7	1
EfficientNet-B0	14	12	1
ConvNeXt-Tiny	5	5	0
Swin-T	7	6	1

本设置 87 个既定组合中，78 个可评价，69 个保留平均负差，9 个平均非负，9 个支持不足。ConvNeXt-Tiny 有 5 个可评价组合且 5 个平均仍较弱；这说明总体表现较高的模型也有可复查的薄弱条件。

“条件数少”不自动表示模型更好，因为发现阶段清单按模型分别形成。更公平的模型比较应使用图 3、图 4 和图 6 的共同层／共同条件；本页回答的是各模型自己的诊断线索能否在新目标上继续检查。

八、另外五种模型的分层表现与训练波动

扩展组为 YOLO26-S-cls、PE-Core-B16、SigLIP2 Base、MobileCLIP2-S0、AIMv2-Large，各 3 个训练种子。沿用相同目标池和本地风险层，但预训练来源、规模及适配配置与主组不同，单独报告。

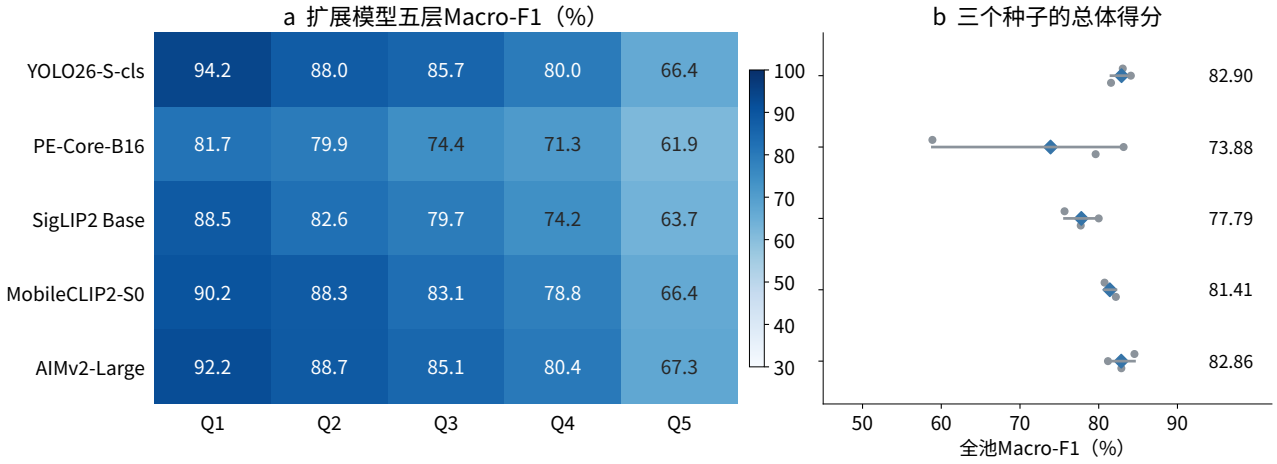


图 8 五种扩展模型的分层差异与种子波动

图 8 说明：左图为五层平均 F1，右图为三个种子各自的全池 F1 及均值；灰线为最小—最大范围。保留所有种子，包含低值结果。

扩展模型	全池 F1：均值 ±SD	Q5 F1	Q1−Q5 落差
YOLO26-S-cls	82.90±1.27%	66.38%	27.80 个百分点
PE-Core-B16	73.88±13.12%	61.90%	19.79 个百分点
SigLIP2 Base	77.79±2.17%	63.73%	24.78 个百分点
MobileCLIP2-S0	81.41±0.72%	66.42%	23.81 个百分点
AIMv2-Large	82.86±1.68%	67.31%	24.91 个百分点

本设置五模型的平均 Q1−Q5 落差均为正。PE-Core-B16 的总体 F1 种子 SD 为 13.12 个百分点，说明当前训练适配对种子敏感；不能据此断言该架构固有能力较差。扩展组未单独重复覆盖选样诊断、随机划层或仅面积对照，不把主组对照结果移作这五模型的直接证据。

可以直接向老师说明的结论

“我把模型放到共同视觉条件下比较。覆盖选样让测试状态支持更充分，并在不同模型上产生不同的诊断增量；风险分层揭示总体成绩不能反映的模型差别；条件报告把这些差别转成背向、小目标、模糊等具体可复查的测试线索。当前贡献是模型测试与诊断方法的实证证据，尚未证明再训练后准确率提升。”

模型数值比较是已测任务中的观察结果，未宣称通用架构排名或逐模型显著提升。数据来自既有预测、分层、等错误数比较及复查记录；本次仅重新汇总与绘图，没有新增训练或 VLM 请求。