# 3 研究方法

本文构建视觉状态驱动的多类别图像分类模型测试框架，以目标的可见视觉条件组织测试样本，并将模型预测转化为条件能力报告。总体流程如图1所示，包含目标样本构建、视觉状态表示、覆盖引导选样、风险引导组织和视觉条件评价。覆盖路线描述各状态获得的测试支持，风险路线组织不同挑战程度的测试条件；两条路线共同使用结构化状态，但分别承担证据分布描述和条件比较的作用。

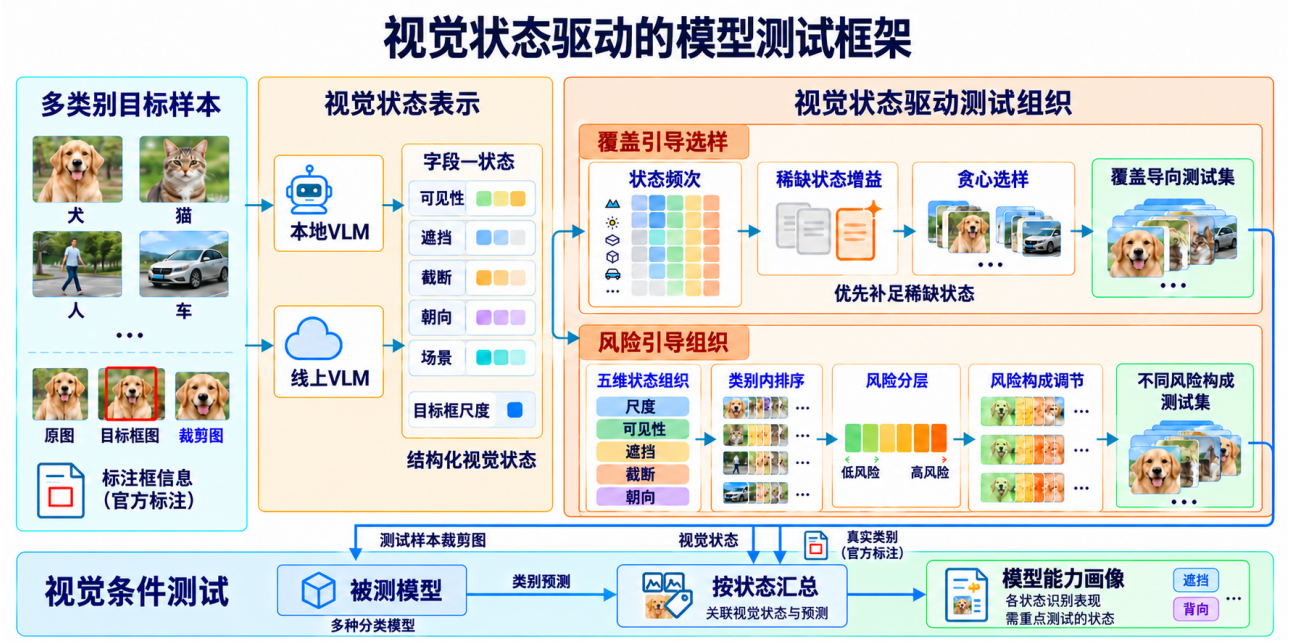



图1 视觉状态驱动的模型测试总体框架。官方标注提供目标框与类别真值，双VLM分别产生结构化状态，程序补充目标尺度。视觉状态用于覆盖引导选样和类别内风险组织。分类模型预测与真实类别、视觉状态关联后，输出各状态识别表现及需重点测试的条件。图中图像和状态标签为示意。

## 3.1 问题定义与信息分工

设候选目标集合为$P$，每个目标由原始图像$I_i$、官方目标框$b_i$及类别标签$y_i$组成。类别集合包含犬、猫、马、羊、人和车，类别数记为$K$，当前实现中$K=6$。根据目标框生成原图、目标框标记图和裁剪图；被测分类器使用经既定预处理后的目标裁剪图$x_i$。

本研究评价已知目标区域上的多类别分类行为。官方类别标签作为分类真值，视觉语言模型（VLM）提供状态描述，被测分类器提供类别预测。三类信息分别用于确定分类对错、组织测试条件和评价模型行为。VLM提示可获得类别信息，其状态输出不作为独立识别结果，也不替代官方真值。

记被测模型为$f_\theta$，测试阶段在模型参数与推理处理一致的条件下比较不同测试集合。每个目标对应的预测可预先计算并复用，改变状态来源或测试组织不改变该目标的分类结果。方法输出为按模型、类别与视觉状态组织的条件能力报告，而非新的分类器参数。

## 3.2 多视图视觉状态表示

为同时获得场景信息和目标细节，将原图$I_i$、目标框标记图$M_i$及放大裁剪图$V_i$输入状态描述器。设标注来源为$r \in \{\text{local}, \text{online}\}$，其输出为：

$$z_i^{(r)} = \phi_r(I_i, M_i, V_i)$$

其中，$\phi_r$表示按预定义字段及有限枚举值进行描述的VLM。当前实现分别使用本地Qwen3-VL与线上SenseNova，两套标注独立用于测试组织和结果分析，不进行分类概率融合。

类别专用协议映射为14项共享字段：身体可见性、身体朝向、遮挡程度、遮挡物类型、截断程度、群体关系、交互关系、场景、背景复杂度、模糊、照明、目标背景对比、可识别性与呈现形式。另以官方目标框面积与原始图像面积之比$a_i$表示目标尺度，按预定义区间离散化后形成第15项分析字段。目标尺度保留目标在原始场景中的相对面积信息，不将裁剪缩放后的输入尺寸当作原图尺度。

将“字段—枚举值”对定义为视觉状态。例如，“身体朝向—背向”表示一种状态。目标$i$在来源$r$下激活的已知状态集合记为$A_i^{(r)}$；多值字段可同时激活多个状态。无法判断的字段保留为unknown，不计为已获得的覆盖证据。结构化校验用于保证输出可解析及枚举合法，不据此认定自动状态具有完整语义准确性。

## 3.3 状态覆盖度量与稀缺状态选样

### 3.3.1 状态支持与频次覆盖

对同一候选池，在类别$c$内将两种标注来源观察到的已知状态取并集，记为状态集合$U_c$。比较不同选样规模与方法时使用相同的$U_c$。对于已选目标索引集合$S$，状态$s$的支持数定义为：

$$n_{c,s}^{(r)}(S) = \sum_{i \in S} \mathbf{1}[y_i = c]\mathbf{1}[s \in A_i^{(r)}]$$

其中，$\mathbf{1}[\cdot]$为指示函数。采用支持数饱和的频次覆盖指标：

$$C_c^{(r)}(S) = \frac{1}{|U_c|} \sum_{s \in U_c} \min\left(\frac{n_{c,s}^{(r)}(S)}{\tau}, 1\right), \qquad C^{(r)}(S) = \frac{1}{K} \sum_{c=1}^{K} C_c^{(r)}(S)$$

$\tau$为状态支持的饱和阈值，当前取20。状态支持达到$\tau$后，其覆盖贡献不再增加。先在类别内平均，再在类别间平均，以避免样本较多的类别主导总体覆盖。该指标描述当前词表与候选池中的单状态证据，不评价全部状态组合；状态集合不同的覆盖百分比不直接比较。

### 3.3.2 稀缺状态增益与贪心选样

为优先增加支持不足状态的测试证据，在类别$c$内计算候选目标$i$相对于当前集合$S$的增益：

$$g_c^{(r)}(i \mid S) = \sum_{s \in A_i^{(r)},\ n_{c,s}^{(r)}(S) < \tau} \left[\log\left(n_{c,s}^{(r)}(S) + 2\right) - \log\left(n_{c,s}^{(r)}(S) + 1\right)\right]$$

已有支持越少，新增目标提供的边际增益越大。在每轮中，从满足当前配额的未选目标中选择增益最大的目标，并更新状态计数。增益相同时按目标ID排序，保证给定输入下选样次序确定。状态计数在同一类别内跨风险层累计。

在选样对照中，各方法使用共同的类别、风险层及风险格配额。风险格由风险中点值与未知维数定义；格内配额依据候选数量比例和最大余数法分配。贪心选择的可行集合由剩余配额限定，以减少测试难度构成差异对选样比较的影响。风险层及风险格的构造见第3.4节。

选样增益采用对数边际增益，报告覆盖采用线性截断贡献，二者分别定义。该策略用于优先补充稀缺状态，不声称严格优化报告覆盖值，也不直接优化错误数量或分类准确率。

## 3.4 类别内风险组织与测试构成调节

### 3.4.1 预定义风险评分

选取尺度、身体可见性、遮挡、截断和朝向五个维度构造视觉风险。设风险维度集合为$D$，第$d$维的映射为$h_d$，目标的综合风险为：

$$H_i^{(r)} = \sum_{d \in D} h_d(i, r)$$

各维度映射如表1所示。尺度分值由$a_i$计算，其他分值由相应来源的状态确定。评分不读取被测分类器的预测、置信度、表征或错误，也不使用VLM的可识别性字段。

| 维度 | 状态或区间及对应分值 |
| --- | --- |
| 目标尺度 | a≥0.10：0；0.03≤a<0.10：1；0.01≤a<0.03：2；a<0.01：3 |
| 身体可见性 | full／most：0；partial：2；minimal：3 |
| 遮挡程度 | none：0；light：1；moderate：2；heavy：3 |
| 截断程度 | none：0；light：0.5；moderate：1；heavy：2 |
| 身体朝向 | front／left_side／right_side／three_quarter：0；back：1；overhead_or_unusual：2 |

表1 预定义风险映射。五项分值相加后的范围为0—13；a为目标框面积与原始图像面积之比。

当某维度为unknown时，主分析使用该维度最大分值的一半，并记录未知维数；以零值和最大值重新评分、分层，作为未知处理的敏感性分析。未知状态仍不计入覆盖，这与风险评分中的不确定性处理承担不同作用。

### 3.4.2 类别内分层与风险混合

在每个真实类别内按风险升序排列，同分按目标ID排序，将目标等分为Q1至Q5。Q1表示相对低风险，Q5表示相对高风险。分层在各候选池及类别内分别开展，不将其解释为跨类别统一的绝对难度阈值。

为考察测试构成对测得性能的影响，对每个类别保留相同目标数量$m$，并调节高风险占比$\rho$。历史主协议从Q5抽取$\rho m$个目标，从Q1至Q4的并集抽取其余目标：

$$T_c^{(r)}(\rho) = \mathrm{Sample}\left(Q_{c,5}^{(r)}, \rho m\right) \cup \mathrm{Sample}\left(\bigcup_{\ell=1}^{4} Q_{c,\ell}^{(r)}, (1-\rho)m\right)$$

Sample表示无放回抽样，$\rho$取能够产生整数样本数且不超出各层容量的值。将各类别目标合并为测试集$T^{(r)}(\rho)$，使测试总量$Km$和类别比例保持一致。对各比例重复抽样，比较同一模型的性能及排名响应。近期模型扩展采用Q1与Q5混合，作为另行说明的协议变体，不与历史Q1—Q4／Q5混合直接混称。

覆盖度量与风险评分不构成递进关系：前者描述状态支持，后者组织视觉条件。提高覆盖不预设提高风险，风险增大也不预设所有相邻层的实测表现严格递减。

## 3.5 视觉条件评价与失败信息广度

### 3.5.1 整体与状态条件表现

被测分类器对目标裁剪图输出类别预测$\hat{y}_i = f_\theta(x_i)$。将预测、官方类别和视觉状态关联，计算测试集的Accuracy、Macro-Precision、Macro-Recall和Macro-F1。Macro-F1按各类别F1取算术平均，不由Macro-Precision与Macro-Recall直接求调和平均。

进一步在真实类别$c$内，统计状态$s$的条件Recall：

$$\mathrm{Rec}_{c,s}^{(r)}(T) = \frac{\sum_{i \in T} \mathbf{1}[y_i = c]\mathbf{1}[s \in A_i^{(r)}]\mathbf{1}[\hat{y}_i = y_i]}{n_{c,s}^{(r)}(T)}$$

该指标表示具有相应视觉状态的该类目标中被正确识别的比例。只有状态支持数大于零时才计算，并同时报告支持数。以该类别在同一目标集合上的总体Recall为参考，定义状态差：

$$\Delta_{c,s}^{(r)}(T) = \mathrm{Rec}_{c,s}^{(r)}(T) - \mathrm{Rec}_c(T)$$

负差表示模型在该状态下的表现低于对应类别参考。状态集合可能重叠，因此各条件差不作为互相独立的错误类型或因果效应。

### 3.5.2 错误数量与失败信息的区分

对选样结果分别统计错误所涉及的视觉状态、真实类别与错误预测类别形成的混淆类型，以及错误目标的表征簇。表征簇描述错误目标的表征多样性，不作为独立缺陷根因的数量。

为比较相同错误数量下的信息广度，在每个真实类别中取两种方法错误数的较小值$q$。设某方法共有$N$个错误，其中一种失败类型出现$e$次，则无放回抽取$q$个错误后观察到该类型的期望贡献为：

$$\mathbb{E}[\mathbf{1}(\text{type observed})] = 1 - \frac{\binom{N-e}{q}}{\binom{N}{q}}$$

对各类型贡献求和并按相应类型集合大小归一化，再进行类别宏平均。无错误时该广度贡献记为零。不同选样规模下的曲线可通过归一化面积汇总；此面积是测试规模曲线的统计量，不是ROC-AUC或分类性能提升。

等错误数处理是分类预测后的评价步骤，不用于提前选择目标。由此分别评价“发现多少错误”和“在相同错误数量下获得多少不同失败信息”。

## 3.6 条件能力报告与薄弱条件复查

以“模型—类别—视觉状态”为报告单位，记录标注来源、状态支持数、条件Recall、类别参考Recall及其差值。结合覆盖支持记录和风险层表现，形成各状态识别表现及需重点测试的条件，即图1中的模型能力画像。

在发现集合中，先对同一架构的不同训练种子汇总条件Recall与类别Recall，再筛选支持数至少20、条件Recall低于类别Recall至少10个百分点的状态。对每个标注来源、每个类别及架构最多保留三项，按表现差从低到高排序，同差时按字段和值排序。

将所选条件用于新目标和外部数据，沿用同一状态定义、类别、架构及评价规则，重新计算支持数与条件差。新数据支持数不足20的条件标为不可评价；支持充分但差异未复现的条件保留相应结果，不以新出现的有利条件替换。对非尺度条件，可在类别内连续面积五分位层中进行状态与已知非状态的描述性比较，以检查粗尺度构成之外的条件关联。

实证比较同时设置类别内随机分层、评分变化及仅面积分层等对照；选样方法在共同风险配额下比较，另以等错误数控制评价失败信息广度。模型间统计先在架构内汇总训练种子，再以架构为比较单位，并按检验家族校正多重比较。具体抽样次数、数据规模、模型配置与检验设置在实验章节说明。

最终报告提供已测视觉条件的能力描述与后续测试对象。候选薄弱条件及其新数据复查结果分别记录。该方法不根据测试组织本身推断模型准确率提升，不将条件关联视为错误的因果解释，也不将测试报告视为已完成模型再训练或修复。