3 研究方法

本文构建视觉状态驱动的多类别图像分类模型测试框架，以目标的可见视觉条件组织测试样本，并将模型预测转化为条件能力报告。总体流程如图 1 所示，包含目标样本构建、视觉状态表示、覆盖引导选样、风险引导组织和视觉条件评价。覆盖路线描述各状态获得的测试支持，风险路线组织不同挑战程度的测试条件；两条路线共同使用结构化状态，分别承担证据分布描述和条件比较的作用。



图 1　视觉状态驱动的模型测试总体框架。官方标注提供目标框与类别真值，双 VLM 分别产生结构化状态，程序补充目标尺度。视觉状态用于覆盖引导选样和类别内风险组织。分类模型预测与真实类别、视觉状态关联后，输出各状态识别表现及需重点测试的条件。图中图像和状态标签为示意。

3.1 问题定义与信息分工

设候选目标集合为 P，每个目标由原始图像 I_i、官方目标框 b_i 及类别标签 y_i 组成。类别集合包含犬、猫、马、羊、人和车，类别数记为 K，当前实现中 $K = 6$。根据目标框生成原图、目标框标记图和裁剪图；被测分类器使用经既定预处理后的目标裁剪图 x_i。

本研究评价已知目标区域上的多类别分类行为。官方类别标签作为分类真值，视觉语言模型（VLM）提供状态描述，被测分类器提供类别预测。三类信息分别用于确定分类对错、组织测试条件和评价模型行为。VLM 提示可获得类别信息，其状态输出不作为独立识别结果，也不替代官方真值。

记被测模型为 f_θ，测试阶段在模型参数与推理处理一致的条件下比较不同测试集合。每个目标对应的预测可预先计算并复用，改变状态来源或测试组织不改变该目标的分类结果。方法输出为按模型、类别与视觉状态组织的条件能力报告，而非新的分类器参数。

主要符号及含义见表 1，后文沿用同一记号。

表 1　主要符号及含义。

符号	含义
P	候选目标集合。
I_i、M_i、V_i	第 i 个目标的原图、目标框标记图与放大裁剪图。
b_i、y_i、x_i	官方目标框、类别真值与分类器预处理后的目标裁剪图。
c、K	真实类别索引与类别数。
r、ϕ_r、$z_i^{(r)}$	标注来源、对应状态描述器及目标的结构化状态输出。
$A_i^{(r)}$	来源 r 下目标 i 激活的已知视觉状态集合。

符号	含义
U_c	类别 c 内两来源观察到的已知状态并集，用于共同词表与分母。
S、T	已选目标索引集合与用于评价的目标索引集合。
$n_{c,s}^{(r)}(S)$	已选集合中类别 c、来源 r、状态 s 的支持数。
$C_c^{(r)}(S)$、$C^{(r)}(S)$	类别内频次覆盖与类别宏平均覆盖。
τ、$g_c^{(r)}(i \mid S)$	覆盖饱和阈值与候选目标的稀缺状态增益。
D、h_d、$H_i^{(r)}$	风险维度集合、维度分值映射与综合风险。
$Q_{c,\ell}^{(r)}$、ρ、m	第 ℓ 个风险层、高风险占比与混合测试每类目标数。
f_θ、$\hat{y}_i$	被测分类器与目标的类别预测。
n、v、t	复杂度分析中的候选数、状态数与选出目标数。
N、q、e	某方法的错误数、两方法匹配错误数与指定类型的错误频数。

3.2 多视图视觉状态表示

为同时获得场景信息和目标细节，将原图 I_i、目标框标记图 M_i 及放大裁剪图 V_i 输入状态描述器。设标注来源为 $r \in \{\text{local}, \text{online}\}$，其输出为：

$$z_i^{(r)} = \phi_r\left(I_i, M_i, V_i\right). \tag{1}$$

其中，ϕ_r 表示按预定义字段及有限枚举值进行描述的 VLM。当前实现分别使用本地 Qwen3-VL 与线上 SenseNova，不进行分类概率融合。主分析分别固定一种来源，以该来源的状态完成覆盖选样、风险组织和条件评价，最终报告注明来源。跨来源选样或评价作为单独的敏感性分析，分别注明选样、风险组织及评价所用来源。具体模型版本、提示及类别协议的字段映射在实验设置与补充材料中说明。

类别专用协议映射为 14 项共享字段：身体可见性、身体朝向、遮挡程度、遮挡物类型、截断程度、群体关系、交互关系、场景、背景复杂度、模糊、照明、目标背景对比、可识别性与呈现形式。另以官方目标框面积与原始图像面积之比 a_i 表示目标尺度，按预定义区间离散化后形成第 15 项分析字段。目标尺度保留目标在原始场景中的相对面积信息，不将裁剪缩放后的输入尺寸当作原图尺度。

将“字段—枚举值”对定义为视觉状态。例如，“身体朝向—背向”表示一种状态。目标 i 在来源 r 下激活的已知状态集合记为 $A_i^{(r)}$；多值字段按集合处理，可同时激活多个不同状态。同一目标对同一状态最多贡献一次支持，不因重复枚举而重复计数。无法判断的字段保留为 unknown，不计为已获得的覆盖证据。结构化校验用于保证输出可解析及枚举合法，不据此认定自动状态具有完整语义准确性。

3.3 状态覆盖度量与稀缺状态选样

3.3.1 状态支持与频次覆盖

对同一候选池，在类别 c 内将两种标注来源观察到的已知状态取并集，记为状态集合 U_c。该并集仅统一类别状态词表和覆盖分母，不合并同一目标的两份标注；每个目标仍使用来源 r 的 $A_i^{(r)}$。某状态只在另一来源中出现时，其在当前来源中的支持数为零。当前来源零支持的状态仍计入分母，以保证同一候选池内跨来源覆盖值使用共同词表；本文不另报仅当前来源词表的分母敏感性结果。比较不同选样规模与方法时使用相同的 U_c。对于已选目标索引集合 S，状态 s 的支持数定义为：

$$n_{c,s}^{(r)}(S) = \sum_{i \in S} \mathbf{1}\{y_i = c\}\ \mathbf{1}\left\{s \in A_i^{(r)}\right\}. \tag{2}$$

其中，$\mathbf{1}\{\cdot\}$ 为指示函数。采用支持数饱和的频次覆盖指标：

$$\begin{aligned} C_c^{(r)}(S) &= \frac{1}{|U_c|} \sum_{s \in U_c} \min\left(\frac{n_{c,s}^{(r)}(S)}{\tau}, 1\right), \\ C^{(r)}(S) &= \frac{1}{K} \sum_{c=1}^{K} C_c^{(r)}(S). \end{aligned} \tag{3}$$

τ 为状态支持的饱和阈值，当前取 20。状态支持达到 τ 后，其覆盖贡献不再增加。先在类别内平均，再在类别间平均，以避免样本较多的类别主导总体覆盖。该指标对状态等权，并在类别间宏平均，未在字段内再次归一化。因此，枚举状态较多的字段具有更大的潜在总贡献；多值字段的一次标注也可支持多个不同状态。该指标描述当前词表与候选池中的单状态证据，不评价全部状态组合；状态集合不同的覆盖百分比不直接比较。

3.3.2 稀缺状态增益与贪心选样

为优先增加支持不足状态的测试证据，在类别 c 内计算候选目标 i 相对于当前集合 S 的增益：

$$g_c^{(r)}(i \mid S) = \sum_{\substack{s \in A_i^{(r)} \\ n_{c,s}^{(r)}(S) < \tau}} \left[\log\left(n_{c,s}^{(r)}(S) + 2\right) - \log\left(n_{c,s}^{(r)}(S) + 1\right)\right]. \tag{4}$$

每个未饱和状态的增益为 $\log\left(n_{c,s}^{(r)}(S) + 2\right) - \log\left(n_{c,s}^{(r)}(S) + 1\right)$，随已有支持数增加而减小，因此支持较少的状态获得较大的边际增益。选样初始集合为空，状态计数为零。在每轮中，仅从当前风险层内、尚未选中且所在风险格仍有剩余配额的目标中选择增益最大的目标，并更新状态计数。增益相同时按目标 ID 排序，保证给定输入下选样次序确定。按 Q1 至 Q5 依次完成各层配额，状态计数在同一类别内跨风险层累计。

在独立确认的选样对照中，各方法使用共同的类别、风险层及风险格配额。风险格由采用 unknown 中点处理的风险分值与未知维数的二元组合定义；各层格内配额依据候选数量比例和最大余数法预先分配。贪心选择的可行集合由当前风险层和格内剩余配额限定。每层完成后检查实际风险格频数是否等于预定配额；本文共同配额比较的预算点位于完整层配额的完成边界，因此各方法在这些预算点具有相同的风险格频数。任意截取某层内部的前缀不自动满足该条件。风险评分及风险层构造见第 3.4 节。发现阶段的匹配对照以覆盖选样结果的风险格频数作为随机选样配额，两种配额设置的适用实验分别说明。

算法 1 给出主覆盖选样的执行过程。设单一来源、单一类别的候选数为 n，状态数为 v，选出目标数为 t。当前实现逐轮扫描可行目标并重新计算状态增益，贪心部分时间上界为 $O(tnv)$；风险排序另需 $O(n \log n)$。稠密状态矩阵及选样记录的空间上界为 $O(nv + n + t)$。该分析不包含 VLM 标注和分类器表征提取的计算成本。

算法 1　共同风险配额约束下的覆盖引导贪心选择。

输入：指定来源 r、类别 c 的状态矩阵、风险层、风险格及格内配额。
输出：选样顺序及层配额完成边界处的预算前缀集合。
1 初始化：$S = \varnothing$，选样顺序为空，各状态支持数为零。
2 for $\ell = 1, \ldots, 5$ do
3 将当前风险层内各格的已选用量置零。
4 while 当前风险层的配额尚未完成 do
5 构造可行集合：当前层内未选中且所在格仍有剩余配额的目标。
6 选择 $g_c^{(r)}(i \mid S)$ 最大的目标，同分按目标 ID 升序。
7 将目标加入 S 并追加到选样顺序，更新状态支持数与格内用量。
8 end while
9 核对当前层的实际风险格频数是否等于预定配额。
10 end for
11 return 选样顺序及各预算前缀集合。

状态计数在风险层循环外初始化，并在各层之间累计。

选样增益采用对数边际增益，报告覆盖采用线性截断贡献，二者分别定义。该策略用于优先补充稀缺状态，不声称严格优化报告覆盖值，也不直接优化错误数量或分类准确率。

3.4 类别内风险组织与测试构成调节

3.4.1 预定义风险评分

选取尺度、身体可见性、遮挡、截断和朝向五个维度构造视觉风险。设风险维度集合为 D，第 d 维的映射为 h_d，目标的综合风险为：

$$H_i^{(r)} = \sum_{d \in D} h_d\,(i, r)\,. \tag{5}$$

各维度映射如表 2 所示。尺度分值由 a_i 计算，其他分值由相应来源的状态确定。该映射为预定义的启发式测试组织规则，不是由分类性能拟合的最优权重。主评分直接累加各维分值，未先将各维归一到相同范围；不同最大分值形成隐含权重，因此不能把此式解释为各维影响相等。评分不读取被测分类器的预测、置信度、表征或错误，也不使用 VLM 的可识别性字段。

维度	状态或区间及对应分值
目标尺度	$a_i \geq 0.10$：0；$0.03 \leq a_i < 0.10$：1；$0.01 \leq a_i < 0.03$：2；$a_i < 0.01$：3
身体可见性	full ／ most：0；partial：2；minimal：3
遮挡程度	none：0；light：1；moderate：2；heavy：3
截断程度	none：0；light：0.5；moderate：1；heavy：2
身体朝向	front ／ left_side ／ right_side ／ three_quarter：0；back：1；overhead_or_unusual：2

表 2　预定义风险映射。五项分值相加后的范围为 0—13；a_i 为目标框面积与原始图像面积之比。

当某维度为 unknown 时，主分析使用该维度最大分值的一半，并记录未知维数；以零值和最大值重新评分、分层，作为未知处理的敏感性分析。未知状态仍不计入覆盖，这与风险评分中的不确定性处理承担不同作用。

3.4.2 类别内分层与风险混合

在每个真实类别内按风险升序排列，同分按目标 ID 排序，将目标等分为 Q1 至 Q5。Q1 表示相对低风险，Q5 表示相对高风险。分层在各候选池及类别内分别开展，不将其解释为跨类别统一的绝对难度阈值。

为考察测试构成对测得性能的影响，对每个类别保留相同目标数量 m，并调节高风险占比 ρ。主分析从 Q5 抽取 ρm 个目标，从 Q1 至 Q4 的并集抽取其余目标：

$$T_c^{(r)}(\rho) = \mathrm{Sample}\left(Q_{c,5}^{(r)}, \rho m\right) \cup \mathrm{Sample}\left(\bigcup_{\ell=1}^{4} Q_{c,\ell}^{(r)}, (1-\rho)m\right). \tag{6}$$

Sample 表示无放回抽样，$\rho \in [0,1]$，且 ρm 与 $(1-\rho)m$ 均为整数，分别不超过 Q5 与 Q1 至 Q4 并集的候选容量。将各类别目标合并为测试集 $T^{(r)}(\rho)$，使测试总量 Km 和类别比例保持一致。对各比例重复抽样；在每个比例及每次重复中，各模型使用同一测试样本集合，以比较性能响应及模型间排名变化。模型扩展分析采用 Q1 与 Q5 混合；两种混合协议对应的模型组、抽样设置和结果在实验章节分别说明。

覆盖度量与风险评分不构成递进关系：前者描述状态支持，后者组织视觉条件。提高覆盖不预设提高风险，风险增大也不预设所有相邻层的实测表现严格递减。

3.5 视觉条件评价与失败信息广度

3.5.1 整体与状态条件表现

被测分类器对目标裁剪图输出类别预测 $\hat{y}_i = f_\theta(x_i)$。将预测、官方类别和视觉状态关联，计算测试集的 Accuracy、Macro-Precision、Macro-Recall 和 Macro-F1。Macro-F1 按各类别 F1 取算术平均，不由 Macro-Precision 与 Macro-Recall 直接求调和平均。

进一步在真实类别 c 内，统计状态 s 的条件 Recall：

$$\mathrm{Rec}_{c,s}^{(r)}(T) = \frac{\sum_{i \in T} \mathbf{1}\{y_i = c\}\ \mathbf{1}\left\{s \in A_i^{(r)}\right\}\ \mathbf{1}\{\hat{y}_i = y_i\}}{n_{c,s}^{(r)}(T)}. \tag{7}$$

该指标表示具有相应视觉状态的该类目标中被正确识别的比例。只有状态支持数大于零时才计算，并同时报告支持数。以该类别在同一目标集合上的总体 Recall 为参考，定义状态差：

$$\Delta_{c,s}^{(r)}(T) = \mathrm{Rec}_{c,s}^{(r)}(T) - \mathrm{Rec}_c(T). \tag{8}$$

负差表示模型在该状态下的表现低于对应类别参考。状态集合可能重叠，因此各条件差不作为互相独立的错误类型或因果效应。

3.5.2 错误数量与失败信息的区分

对选样结果分别统计失败状态广度、混淆类型广度与表征簇广度。失败状态广度为已选集合中满足预设支持门槛且包含至少一个分类错误的视觉状态数，占该类别固定状态集合 U_c 的比例，再进行类别宏平均。该支持门槛当前取 3，用于判断状态是否具有基本测试支持，与第 3.6 节的薄弱条件筛选门槛分别设置。失败状态广度未经等错误数控制，可能随错误数量增加而增大，也直接依赖用于选样的自动状态词表，故作为描述性指标，与对应错误数量和错误率同时报告，不据此单独认定获得了更多

独立失败信息。

混淆类型由真实类别与错误预测类别的配对定义，其广度为所选错误覆盖的混淆类型比例。对于给定模型、训练种子和真实类别，归一化分母取其在完整候选池中实际出现的错误预测类别数。表征簇广度为所选错误覆盖的表征簇比例；在完整候选池中，先对同一真实类别的全部错误目标表征聚类，再以所得簇数为分母。比较不同选样方法和规模时，沿用相同的类型集合与聚类结果。选样独立确认的主分析使用被测分类器最终分类层的输入表征，另以统一 ViT-B/16 表征作敏感性分析；风险混合分析使用统一 ViT-B/16 表征。错误表征先进行 L2 归一化，再以 K-means 聚类。错误数不少于 2 时，簇数取其平方根四舍五入后截在 2 至 8 之间；零错误和单错误分别对应零簇和一簇。初始化次数与随机种子在实验设置中给出。

即使使用统一表征，错误子集及其聚类仍按模型、训练种子和真实类别分别构建。因此，不同模型的分母及簇含义可能不同；主要比较同一模型内不同选样方法的配对差异，再按实验统计规则汇总，不把跨模型的原始簇比例解释为相同失败类型集合上的绝对排名。表征簇用于描述错误目标的表征多样性，不解释为独立缺陷根因。

为比较相同错误数量下的信息广度，仅对混淆类型与表征簇进行等错误数控制。在每个真实类别中，取两种方法错误数的较小值 q。设某方法共有 N 个错误，其中一种混淆类型或表征簇出现 e 次，则无放回抽取 q 个错误后观察到该类型的期望贡献为：

$$\mathbb{E}[\mathbf{1}\{\text{type observed}\}] = 1 - \frac{\binom{N-e}{q}}{\binom{N}{q}}. \tag{9}$$

上式在 $N > 0$、$0 \le q \le N$ 时计算；若 $q > N - e$，分子组合数取零。分别对两类指标的类型贡献求和，按上述完整候选池中的类型数或簇数归一化，再进行类别宏平均。若 q 为零或相应分母为零，广度贡献记为零，同时注明缺少可比较的错误证据。不同选样规模下的曲线可通过归一化面积汇总；此面积是测试规模曲线的统计量，不是 ROC-AUC 或分类性能提升。

等错误数处理是分类预测后的评价步骤，不用于提前选择目标。错误数量与信息广度分别回答“发现多少错误”和“在相同错误数量下获得多少不同失败信息”。

3.6 条件能力报告与薄弱条件复查

将模型预测、真实类别与视觉状态关联，以“模型—类别—视觉状态”为单位，汇总标注来源、状态支持数、条件 Recall 及其相对于类别总体 Recall 的差异，形成模型能力画像。该报告描述模型在不同视觉条件下的识别表现，并据此提出需重点测试的候选薄弱条件。

根据预先确定的支持量与性能差标准筛选候选条件，在查看新数据评价结果前确定条件清单，再沿用相同状态定义及评价规则进行复查。分别记录得到支持、未复现及支持不足的条件，候选清单不依据复查结果调整，形成可追溯的条件诊断结果。具体筛选阈值与验证设置在实验章节说明。

3.7 参数依据、可靠性检验与适用边界

覆盖饱和阈值 20 与失败状态支持门槛 3 均为预先规定的操作性支持规则，不作为统计显著性的门槛。薄弱条件阈值在实验章说明。五等分用于保持各层目标数量一致；unknown 中点是区间中点替代，不解释为真实难度期望。现有分析未系统改变覆盖阈值、薄弱条件阈值或分层数量，不声称这些取值最优。

风险检验包括 unknown 零值与最大值处理、逐维删除、各维最大分值归一化后求和、仅面积分层及类别内随机五等分。归一化求和用于检验风险分层的表现差异及模型排序是否依赖各维原有分值

范围，不预设该变体改善区分度。随机五等分检验分层区分度，不替代分层数量敏感性。覆盖选样在共同配额约束下与 Random、DeepGini、DSA、k-center 及删除风险相关字段的 Coverage 方法进行比较；统计单位、检验家族和多重比较设置见实验章。

自动状态检查计算双 VLM 逐字段精确一致率、集合 Jaccard 及集合编码的 Kappa，并记录 unknown 与分歧。事后标签分歧敏感性分析沿用原风险层，在指定字段一致且已知的子集上重新评价，报告类别和风险层保留量；支持不足则不可评价。双 VLM 一致不等同语义真值。官方遮挡、截断属性的二值参考仅用于对应字段，不外推为全协议准确率。

状态噪声可影响选样、分层和条件表现；状态重叠、启发式评分及表征依赖也限制诊断解释。最终输出为条件能力报告与待复查条件，不用于推断错误因果、部署准确率或再训练收益。