3 研究方法

本文以犬、猫、马、羊、人和车六类目标为对象，研究如何对已训练的图像分类模型开展视觉条件测试，判断模型在什么条件下能够正确识别目标、在哪些条件下表现较弱，以及测得的性能如何随测试样本构成变化。测试阶段保持模型参数固定，以目标尺度、身体可见性、遮挡、截断和朝向等可观察条件组织样本，使总体分类分数能够对应到具体的测试条件。

方法从带有官方目标框和类别标签的图像出发。首先，为每个目标生成视觉状态描述；随后，一方面根据状态支持数选择测试样本，优先补充测试支持不足的条件，另一方面根据五维视觉风险划分目标，构建不同风险组成的测试集合。将这些目标的分类预测与真实类别、视觉状态关联后，评价整体性能、条件表现和失败信息，再把发现的薄弱条件放到新数据中复查。覆盖选样和风险组织共同使用视觉状态，分别用于安排测试支持和构造条件比较。

方法最终形成三类结果：状态覆盖报告，说明测试样本支持了哪些视觉条件；条件性能与失败分析，说明模型在这些条件下的识别表现及发现的错误类型；薄弱条件复查报告，说明发现的性能差异是否在新数据中继续出现。以下六个小节围绕这一流程展开，具体实验结果在实验章节报告。



图 1　视觉状态驱动的图像分类模型测试框架。官方标注确定测试目标与真实类别，视觉语言模型描述目标的视觉状态，程序计算目标尺度。依据状态覆盖和视觉风险组织测试，再将分类预测与视觉状态关联，形成条件能力报告。图中的图像和状态标签为示意。

3.1 测试问题与五维视觉条件定义

本文研究利用视觉条件构建测试集合并诊断图像分类模型的识别表现。具体任务是：给定一个已训练的分类模型和候选图像集合，在规定的测试样本数量下，依据目标的视觉状态选择和组织样本，评价模型在不同条件下的分类表现，并形成能够在新数据中复查的薄弱条件清单。当前测试任务包含犬、猫、马、羊、人和车六个类别。

这一问题源于整体性能评价所提供的信息有限。整体准确率汇总了测试目标的分类结果，但不能直接说明哪些视觉条件获得了测试支持，以及模型在哪些条件下表现较弱。例如，若犬类测试样本主要是大尺度、完整可见的目标，较高的犬类识别分数仍不足以说明模型对小尺度、重度遮挡或背向犬类目标的表现。因此，需要把测试样本的视觉条件与模型预测关联，明确“测试了哪些条件”和“模型在这些条件下表现如何”。

围绕这一目标，本文开展三项相互关联的工作。首先，统计各视觉状态的样本支持，在给定测试数量下优先补充支持不足的状态。其次，依据视觉风险划分目标，比较不同条件下的性能，并在测试总量和类别比例一致时调节高风险目标占比，分析测得性能对测试构成的响应。最后，识别相对于类

别总体表现较弱的视觉状态，在新数据中检查薄弱方向是否复现。状态支持描述测试证据，分类结果描述模型表现，两者共同构成条件能力报告。

测试单位为官方目标框确定的单个目标。设候选目标集合为 P，每个目标包含原始图像 I_i、官方目标框 b_i 和真实类别标签 y_i。根据目标框生成裁剪图，经既定预处理后得到输入 x_i。被测分类器记为 f_θ，类别数记为 K。分类器对裁剪图预测类别，官方标签用于判断预测是否正确。测试阶段保持模型参数与推理处理一致，每个目标的预测可以预先计算并复用。

为明确测试条件，本文将目标尺度、身体可见性、遮挡程度、截断程度和身体朝向定义为五个核心视觉维度，用于描述目标的大小、可见完整程度、缺失情况和观察方向，并据此开展风险组织。各维度的描述对象和状态划分如下。

表 1　五维视觉条件的定义与状态划分。

维度	定义、状态划分与判断要点
目标尺度	描述目标在原始图像中占据的相对面积。以官方目标框面积与原图面积之比 a_i 表示，分为极小（tiny，$a_i < 0.01$）、小（small，$0.01 \le a_i < 0.03$）、中（medium，$0.03 \le a_i < 0.10$）和大（large，$a_i \ge 0.10$）四档。
身体可见性	描述目标整体被呈现的完整程度，分为完整可见（full）、大部分可见（most）、部分可见（partial）和仅少量可见（minimal）。动物和人物对应身体整体，车辆对应整辆车。该维度记录可见结果，缺失原因由遮挡与截断分别描述。
遮挡程度	描述目标被其他可见物体遮蔽的程度，分为无遮挡（none）、轻度遮挡（light）、中度遮挡（moderate）和重度遮挡（heavy）。例如，栏杆挡住目标腿部，或其他目标挡住其身体，均属于遮挡。
截断程度	描述目标超出图像或裁剪边界而产生的缺失，分为无截断（none）、轻度截断（light）、中度截断（moderate）和重度截断（heavy）。例如，头部或腿部超出画面边缘属于截断，应结合原图与裁剪图判断。
身体朝向	描述目标整体相对于观察视角的方向，分为正向（front）、背向（back）、左侧（left_side）、右侧（right_side）、斜向（three_quarter）以及俯视或非常规视角（overhead_or_unusual）。左右侧以目标自身方位为准；车辆的正向与背向分别对应车头与车尾朝向镜头。

目标尺度按下式计算，其中 w_i 和 h_i 为官方目标框的宽、高，W_i 和 H_i 为原图的宽、高：

$$a_i = \frac{w_i h_i}{W_i H_i}. \tag{1}$$

该尺度保留目标在原始场景中的面积占比；裁剪图缩放为固定输入尺寸后，仍使用原图尺度。身体可见性、遮挡和截断采用定性等级，具体描述遵循标注协议，不另设未经验证的面积比例阈值。无法可靠判断的状态记为 unknown。例如，一个目标可以同时具有“小尺度、部分可见、中度遮挡、无截断、背向”等条件，五个维度并非互相排斥。

五维条件是风险组织的预定义子集。背景、模糊、照明等其他视觉状态仍用于覆盖统计和条件评价。头部、腿部、尾部等局部可见性可由类别专用协议进一步描述，但这些局部字段未进入当前六分类共享分析；整体可见性等级也不能直接推得各部位的可见状态。

方法输出包含三个部分：各状态获得多少测试支持的覆盖报告；模型在不同状态和风险条件下的性能与失败分析；包含状态支持数、条件表现及新数据复查状态的薄弱条件清单。后续第 3.2 节提取状态，第 3.3 和 3.4 节选择并组织样本，第 3.5 节评价模型行为，第 3.6 节生成并复查薄弱条件清单。

3.2 测试目标的视觉状态提取与表示

本节将目标的可观察视觉条件转化为能够计数、选样和分组的结构化状态。例如，把目标的观察方向记为“身体朝向—背向”，把遮蔽情况记为“遮挡程度—重度遮挡”。这些状态随后用于统计测试支持和组织风险条件。

为了同时描述场景信息与目标细节，对每个目标构建原始图像 I_i、目标框标记图 M_i 和放大裁剪图 V_i。原图提供场景上下文，标记图明确待描述目标，放大裁剪图补充局部信息。三种视图共同输入视觉语言模型（VLM），按照预定义字段和有限枚举值生成结构化描述：

$$z_i^{(r)} = \phi_r(I_i, M_i, V_i). \tag{2}$$

其中，r 表示标注来源，ϕ_r 为相应的状态描述器，$z_i^{(r)}$ 为目标的状态输出。当前采用本地 Qwen3-VL 与线上 SenseNova，两种来源分别描述同一目标。主分析固定一种来源，用该来源的状态完成选样、风险组织和条件评价；跨来源分析另行注明各步骤所使用的来源。模型版本和完整提示在实验设置与补充材料中说明。

类别专用协议映射为 14 项共享字段：身体可见性、身体朝向、遮挡程度、遮挡物类型、截断程度、群体关系、交互关系、场景、背景复杂度、模糊、照明、目标背景对比、可识别性与呈现形式。程序计算的目标尺度作为第 15 项字段。由此形成用于当前六分类分析的共享状态表示。

将“字段—枚举值”对称为一个视觉状态，例如“身体朝向—背向”。目标 i 在来源 r 下具有的已知状态集合记为 $A_i^{(r)}$。一个目标可以支持多个状态；多值字段按集合记录，同一目标对同一状态最多计数一次。unknown 保留在标注中，但不计入已获得的状态覆盖。

官方类别标签提供分类真值，VLM 提供状态描述，被测分类器提供类别预测。VLM 接收三种视图完成状态描述，分类器仍使用既定预处理后的目标裁剪图完成分类。VLM 提示可获得类别信息，状态描述不替代真实类别。输出校验检查字段、枚举和格式是否合法；自动状态的语义可靠性通过来源一致性、分歧敏感性及可用参考属性等分析评价，具体结果在实验章节报告。

3.3 基于视觉状态覆盖的测试样本选择

本节解决有限测试数量下如何安排视觉条件的样本支持。对已有较多样本的常见状态，限制重复支持的覆盖贡献；对样本较少的状态，通过选样优先增加支持。例如，当“犬—背向”获得的支持不足时，具有该状态的候选目标可以提供新增测试证据。状态覆盖描述这种证据分布，分类预测随后用于评价相应条件下的模型表现。

在类别 c 内，对两种来源观察到的已知状态取并集，形成共同状态集合 U_c。该集合统一覆盖计算的词表和分母，每个目标仍使用指定来源的状态。若某状态只在另一来源中出现，其在当前来源中的支持数为零，仍保留在共同分母中。

设 S 为已选目标的索引集合，状态 s 的支持数为：

$$n_{c,s}^{(r)}(S) = \sum_{i \in S} \mathbf{1}\{y_i = c\} \mathbf{1}\{s \in A_i^{(r)}\}. \tag{3}$$

其中，$\mathbf{1}\{\cdot\}$ 为指示函数，条件成立时取 1，否则取 0。为限制常见状态的重复样本持续增加覆盖值，设置支持数饱和阈值 τ，并定义类别覆盖及总体覆盖：

$$
\begin{aligned}
C_c^{(r)}(S) &= \frac{1}{|U_c|} \sum_{s \in U_c} \min\left(\frac{n_{c,s}^{(r)}(S)}{\tau}, 1 \right), \\
C^{(r)}(S) &= \frac{1}{K} \sum_{c=1}^{K} C_c^{(r)}(S).
\end{aligned}
\tag{4}
$$

当前固定 $\tau = 20$。状态支持数不足 20 时，新增样本会增加其覆盖贡献；达到 20 后，贡献保持为 1。先在类别内平均，再对类别平均，避免样本较多的类别主导总体结果。同一候选池内比较不同方法与样本数量时，沿用相同的状态集合和阈值。覆盖对状态等权，未再次按字段均衡，因此枚举状态较多的字段具有更大的潜在贡献。该指标描述单状态的样本支持，不覆盖全部状态组合，也不直接比较不同词表下的覆盖百分比。

覆盖引导选样优先补充支持不足的状态。候选目标 i 对当前集合 S 的增益定义为：

$$
g_c^{(r)}(i \mid S) = \sum_{\substack{s \in A_i^{(r)} \\ n_{c,s}^{(r)}(S) < \tau}} \left[\log\left(n_{c,s}^{(r)}(S) + 2 \right) - \log\left(n_{c,s}^{(r)}(S) + 1 \right) \right]. \tag{5}
$$

已有支持数越少，该状态的边际增益越大。选样从空集开始，每轮选取可行候选中增益最大的目标，更新状态支持数；增益相同时按目标 ID 升序选择。报告覆盖采用线性截断贡献，选样采用对数边际增益，两者分别定义。该策略用于补充稀缺状态，不直接优化分类准确率或错误数量。

在独立确认的选样对照中，各方法使用共同的类别、风险层和风险格配额。风险层由第 3.4 节定义；风险格由风险分值与未知维数的组合确定。各层格内配额依据候选数量比例和最大余数法分配，即先取比例名额的整数部分，再将剩余名额依次分给小数余数最大的格。按 Q1 至 Q5 依次选样，每轮只考虑当前层内未选中且所在格仍有剩余配额的目标，状态计数在类别内跨层累计。

完成每层后核对风险格频数。在完整层配额的完成边界，各方法具有相同的风险格构成；任意截取层内部的样本前缀不自动满足这一条件。发现阶段的匹配随机对照以覆盖选样结果的风险格频数分配名额，具体适用实验在实验章节区分。配额约束控制规定的风险构成，不保证其他视觉属性完全一致。

3.4 基于视觉风险分层的测试集构建

本节根据五维视觉条件构建风险层和混合测试集合，评价模型的表现如何随视觉条件变化。先在各类别内划分相对低风险至高风险的目标，比较不同层的性能；再保持测试总量和类别比例一致，调节高风险目标占比，观察测得性能的响应。

根据第 3.1 节定义的五维条件，预先设置各状态的分值。设风险维度集合为 D，目标 i 的综合风险记为 $R_i^{(r)}$：

$$
R_i^{(r)} = \sum_{d \in D} h_d(i, r). \tag{6}
$$

其中，$h_d(i, r)$ 为第 d 维的分值映射。具体规则见表 2。

表 2　五维视觉条件的风险赋分规则。

维度	状态及对应分值
目标尺度	大：0；中：1；小：2；极小：3。尺度区间沿用表 1。
身体可见性	完整可见或大部分可见：0；部分可见：2；仅少量可见：3。
遮挡程度	无遮挡：0；轻度遮挡：1；中度遮挡：2；重度遮挡：3。
截断程度	无截断：0；轻度截断：0.5；中度截断：1；重度截断：2。
身体朝向	正向、左侧、右侧或斜向：0；背向：1；俯视或非常规视角：2。

五项直接求和，综合风险范围为 0 至 13。各维最大分值不同，直接求和具有隐含权重。该规则是预定义的测试组织方式，不由分类性能拟合，也不读取模型预测、置信度、表征或错误信息。可识别性等其他字段不参与风险评分。

某维度为 unknown 时，使用该维可能分值范围的中点，并记录未知维数；同时分别取零值和最大值重新评分、分层，检查结论对未知处理的依赖。中点是操作性替代值，不表示真实难度的期望。unknown 在覆盖计算中仍不作为已知状态证据。

在每个候选池、每个真实类别内，按风险升序排列，同分按目标 ID 排序，将目标分为数量尽可能相等的 Q1 至 Q5 五层。Q1 表示该类别内相对低风险，Q5 表示相对高风险。随后分别计算各层的模型表现，检验风险组织与实际分类表现的关系。风险层不作为跨类别统一的绝对难度等级，也不预设各相邻层的表现严格递减。

为分析测试构成的影响，每个类别保留相同目标数量 m，调节高风险目标占比 ρ。主分析从 Q5 抽取 ρm 个目标，从 Q1 至 Q4 的并集抽取其余目标。记低风险侧候选集合为 $L_c^{(r)} = Q_{c,1}^{(r)} \cup Q_{c,2}^{(r)} \cup Q_{c,3}^{(r)} \cup Q_{c,4}^{(r)}$，则：

$$\begin{aligned} T_c^{(r)}(\rho) = \ & \mathrm{Sample}(Q_{c,5}^{(r)}, \rho m) \\ & \cup \mathrm{Sample}(L_c^{(r)}, (1-\rho)m). \end{aligned} \tag{7}$$

Sample 表示无放回抽样，$\rho \in [0,1]$，两部分样本数均取整数且不超过相应候选容量。合并各类别后，测试总量为 Km，类别比例保持一致。每个比例重复抽样，同一次抽样中各模型使用相同测试集合，以比较性能响应和模型排名变化。模型扩展分析采用 Q1 与 Q5 混合，两种协议对应的模型组和抽样设置在实验章节分别说明。

覆盖描述状态的样本支持，风险组织用于比较视觉条件。二者共同依赖视觉状态，但承担不同作用；覆盖增加不预设风险增加。

3.5 不同视觉条件下的模型性能与失败分析

本节将已组织的测试集合转化为模型评价结果，分别分析整体识别表现、具体视觉条件下的表现，以及测试发现的失败信息。被测模型输出类别预测 $\hat{y}_i = f_\theta(x_i)$。首先计算测试集合的 Accuracy、Macro-Precision、Macro-Recall 和 Macro-F1，评价整体分类表现。Macro-F1 为各类别 F1 的算术平均。随后按照风险层和具体视觉状态划分目标，分析模型表现的条件差异。

设 T 为评价目标的索引集合，类别 c 中具有状态 s 的目标，其条件 Recall 定义为：

$$\mathrm{Rec}_{c,s}^{(r)}(T) = \frac{\sum_{i \in T} \mathbf{1}\{y_i = c\} \mathbf{1}\{s \in A_i^{(r)}\} \mathbf{1}\{\hat{y}_i = y_i\}}{n_{c,s}^{(r)}(T)}. \tag{8}$$

该指标表示具有相应状态的该类目标中被正确识别的比例。例如，“犬—重度遮挡”的条件 Recall 表示重度遮挡犬类目标中被正确识别为犬的比例。指标仅在支持数大于零时计算，并同时报告支持数。以该类别在同一评价集合中的总体 Recall 为参考，定义条件差值：

$$\Delta_{c,s}^{(r)}(T) = \mathrm{Rec}_{c,s}^{(r)}(T) - \mathrm{Rec}_{c}(T). \tag{9}$$

差值为负表示该状态下的表现低于对应类别的总体水平。一个目标可能同时属于多个状态，因此条件差值描述的是状态与表现的关联，不直接解释为独立错误类型或错误原因。

为了评价不同选样方法获得的失败信息，除错误数量和错误率外，还统计三类广度。失败状态广度描述具有基本样本支持且出现分类错误的状态比例，当前基本支持门槛为 3，分母为该类别固定状态集合 U_c。该指标未进行等错误数控制，与错误数量共同报告。混淆类型广度描述所选错误覆盖了多少种真实类别与错误预测类别的配对，例如“犬被预测为猫”。表征簇广度描述所选错误覆盖了多少个错误样本表征簇，用于观察错误目标在模型表征中的多样性。

对于每个模型、训练种子和真实类别，混淆类型集合由完整候选池中的错误确定；表征簇也仅对完整候选池中的错误目标构建。不同选样方法和测试数量沿用固定的类型集合、聚类结果和分母。错误表征先进行 L2 归一化，再使用 K-means 聚类。错误数不少于 2 时，簇数取错误数平方根四舍五入后限制在 2 至 8 之间；零错误和单错误分别对应零簇和一簇。选样独立确认主分析使用分类器最终分类层的输入表征，另用统一 ViT-B/16 表征检查敏感性；风险混合分析使用统一 ViT-B/16 表征。

为减少错误数量不同对广度比较的影响，对混淆类型和表征簇进行等错误数控制。在每个真实类别内，取两种方法错误数的较小值 q。若某方法共有 N 个错误，其中某一类型出现 e 次，则无放回抽取 q 个错误后观察到该类型的概率为：

$$p_{\mathrm{obs}} = 1 - \frac{\binom{N-e}{q}}{\binom{N}{q}}. \tag{10}$$

对所有类型的概率求和，得到等错误数下预期观察到的类型数量，再除以固定类型总数，并进行类别平均。若 $q > N - e$，分子组合数取零；若 $q = 0$ 或类型分母为零，广度贡献记为零，并注明缺少可比较的错误证据。该处理在获得分类预测后开展，不用于提前选样。

表征簇反映错误样本的表征多样性，不等同于独立缺陷。跨模型比较先计算各模型内不同选样方法的配对差异，再按架构汇总，避免直接用不同错误集合下的原始簇比例对模型排名。

3.6 模型薄弱视觉条件的识别与新数据复查

本节从条件评价中识别表现较弱的视觉状态，并检查这种薄弱方向是否在新数据中继续出现。例如，若“犬—重度遮挡”满足预先规定的筛选条件，就将该条件列入复查清单，使用新数据中的重度遮挡犬类目标重新评价。复查结果用于判断观察到的条件关联能否跨数据集复现。

根据条件评价结果，形成按数据集、标注来源、模型架构、训练种子、真实类别和视觉状态组织的条件能力报告。报告记录状态支持数、条件 Recall、类别总体 Recall 及二者差值，使识别表现与样本依据同时可见。

在发现集合中，先对同一架构不同训练种子的条件 Recall 与类别 Recall 取平均。将支持数不少于 20、平均条件 Recall 低于类别总体 Recall 至少 10 个百分点的状态列为候选薄弱条件。每个标注来源、类别和架构最多保留三项，按差值从低到高排序；同差时按字段和枚举值排序，不足三项时不补选。条件清单在查看新数据分类预测前确定。

复查使用与既有训练、验证及研究样本排重的新目标集合，保持类别任务、视觉状态定义和分类

器一致。目标框由新数据源的官方标注提供，同类多目标时选取最大合法框。新集合的构建不依据分类器错误或待复查条件筛选样本。当前使用 COCO、VOC2007 和 Objects365 开展复查，数据来源、规模和排重设置在实验章节说明。

对清单中的每个条件，分别计算各训练种子在新数据中的状态支持数和 Recall 差值。支持数不少于 20 且差值仍为负，记为“薄弱方向复现”；支持充分但差值非负，记为“未复现”；支持数不足 20，记为“支持不足”。方向复现要求该状态仍低于对应类别参考，不要求再次达到发现阶段 10 个百分点的落差，也不等同于逐项统计显著。

所有复查结果均保留，不根据新数据表现替换候选条件。各训练种子的结果分别记录，并报告架构内种子均值；整体比较先在每个架构、种子内平均可评价条件的差值，再在架构内平均种子，以架构为统计单位。最终报告呈现哪些条件表现较弱、这些判断获得多少样本支持，以及薄弱方向是否在新数据中复现。